

Reto SIIMA: calidad del aire en el Área Metropolitana de Monterrey

Etapa 1. Preparación de los datos

Nombres y matrículas

Nombre completo: _____ Matrícula: _____

Nombre completo: _____ Matrícula: _____

Nombre completo: _____ Matrícula: _____

Nombre completo: _____ Matrícula: _____

Curso: Análisis multivariado (MA2003B)

Profesor(a):

Fecha de entrega: 1 de octubre de 2026

Parte I. Conociendo el negocio

1.1 El socio formador: SIMA

El Sistema Integral de Monitoreo Ambiental (SIMA) es la red de monitoreo de la calidad del aire del Gobierno de Nuevo León. Opera desde el 20 de noviembre de 1992 y su centro de control, el C5 Ambiental, se inauguró el 5 de junio de 2026 (SIMA, 2026). Sus 15 estaciones automáticas en la Zona Metropolitana de Monterrey (ZMM) miden cada hora seis contaminantes criterio (PM10, PM2.5, O3, SO2, NO2 y CO) y siete variables meteorológicas.

Los datos pasan por una prevalidación automática, que exige 75 % de completitud y revisa banderas de falla, y después por revisiones manuales horarias, semanales y mensuales. Con ellos, SIMA calcula cada hora el Índice Aire y Salud (que sustituyó al IMECA en 2020), elabora pronósticos y activa el Programa de Respuesta a Contingencias Atmosféricas (SIMA, 2026).

El PIGECA 2023–2033 le asigna el propósito de generar información “confiable, representativa, oportuna y verificable” para evaluar la calidad del aire, sus impactos en la salud y la gestión ambiental. Nuestro proyecto se vincula con cuatro de sus medidas transversales: fortalecimiento del SIMA (1T), pronóstico (4T), gestión de contingencias (6T) y comunicación (9T) (Secretaría de Medio Ambiente del Estado de Nuevo León [SMA] y Clean Air Institute [CAI], 2024).

1.2 Importancia de la calidad del aire para la salud

Orellano et al. (2020), en un metaanálisis de 196 artículos, encontraron asociaciones positivas entre la exposición de corto plazo a PM10, PM2.5, NO2 y O3 y la mortalidad por todas las causas. Las partículas se asociaron además con mortalidad cardiovascular, respiratoria y cerebrovascular.

Las PM2.5 son las más preocupantes porque, por su tamaño, llegan a los alvéolos pulmonares. Los contaminantes primarios se emiten directamente; los secundarios, como el O3, se forman en la atmósfera a partir de precursores y radiación solar.

La Organización Mundial de la Salud redujo en 2021 su guía de PM2.5 a 15 $\mu\text{g}/\text{m}^3$ en 24 h y 5 $\mu\text{g}/\text{m}^3$ anual (World Health Organization, 2021). En la ZMM las partículas rebasan esos lineamientos, lo que el PIGECA reconoce como un riesgo significativo (SMA y CAI, 2024). Además, el PM10 muestra un ciclo anual, más alto en otoño-invierno, y concentraciones mayores en el occidente y en las zonas de mayor altitud (Aguirre-López et al., 2022).

1.3 Medición, variables y normas

Hay que distinguir tres referencias:

1. el **rango instrumental**, que delimita lo que el equipo puede medir y sirve para detectar errores;
2. el **límite normativo de salud**, que se define con un periodo de promedio;
3. el **Índice Aire y Salud** (NOM-172-SEMARNAT-2023; SEMARNAT, 2024), que comunica el riesgo cada hora.

En nuestros datos, las partículas se reportan en $\mu\text{g}/\text{m}^3$, el CO en ppm y el resto de los gases en ppb; las normas expresan los gases en ppm (1 ppm = 1000 ppb). Los límites de salud se endurecen gradualmente. A diciembre de 2025 son:

Contaminante	Norma	Promedio	Límite
PM10	NOM-025-SSA1-2021	24 h	50 $\mu\text{g}/\text{m}^3$
PM2.5	NOM-025-SSA1-2021	24 h	25 $\mu\text{g}/\text{m}^3$

Contaminante	Norma	Promedio	Límite
O3	NOM-020-SSA1-2021	1 h / 8 h móvil	0.090 / 0.051 ppm

Fuente: SIMA (2026).

Esta gradualidad complica comparar años, porque parte del aumento de excedencias se debe al cambio del límite (Hernández-Romero et al., 2026). SIMA señala además que las normas de salud se endurecen sin un cambio equivalente en las normas de emisión (SIMA, 2026).

1.4 Dificultades de la medición

Medir continuamente la calidad del aire implica varias dificultades:

- **Datos faltantes.** Fallas eléctricas, calibraciones y periodos fuera de línea invalidan horas (SIMA, 2026). El PIGECA reconoce que en algunos años no hay suficientes datos válidos para ciertos contaminantes y estaciones (SMA y CAI, 2024).
- **Errores instrumentales.** Valores fuera de rango, ceros, negativos, valores repetidos y saltos bruscos.
- **Inconsistencias entre variables.** Por eso SIMA compara PM10 con PM2.5 y revisa los cambios de más de 10 °C o 10 mm Hg en una hora (SIMA, 2026).
- **Representatividad espacial.** Cada estación refleja sus fuentes cercanas (Hernández-Romero et al., 2026).
- **Cambios en la red.** La red cambia con el tiempo: se agregan estaciones y no todas miden todas las variables (SMA y CAI, 2024).

Estas dificultades obligan a fijar criterios explícitos de limpieza (Parte II).

1.5 Antecedentes

Los estudios con datos de SIMA analizan un contaminante a la vez:

- **Aguirre-López et al. (2022)** estudiaron el PM10 mensual de siete estaciones entre 2010 y 2018. Reportan una tendencia decreciente con ciclo anual y proponen, como trabajo futuro, incorporar variables meteorológicas.
- **Hernández-Romero et al. (2026)** analizaron la persistencia de excedencias de PM10, PM2.5 y O3 en cinco estaciones entre 2019 y 2023. Usaron pruebas no paramétricas, correlaciones de Spearman por pares y una descomposición temporal sin regresores meteorológicos. Encontraron que ninguna estación cumplió de forma continua la norma de PM10 y que las partículas alcanzan su máximo en la temporada seca-fría, mientras que el O3 lo alcanza en las cálidas.
- **Ramírez-Velarde et al. (2024)** combinaron componentes principales y clasificadores para anticipar contingencias con meteorología de SIMA.
- **Hernandez-Santiago et al. (2026)** modelaron el O3 horario con XGBoost y validaron por temporadas.
- **Martínez-Cinco et al. (2016)**, desde la química, mostraron que el PM2.5 otoñal está dominado por emisiones vehiculares y se acumula con viento débil, mientras que en verano aumenta el sulfato secundario.

Fuera de México, el análisis multivariado se ha usado para clasificar patrones de contaminación:

- **Mohd Shafi'i y Juahir (2024)** combinaron conglomerados, discriminante y componentes principales para agrupar estaciones.
- **Elmourssi et al. (2026)** identificaron regímenes de contaminación con k-medias y evaluaron su estabilidad entre años.

1.6 Problema, pregunta y objetivos

Problema. SIMA gestiona y comunica la calidad del aire contaminante por contaminante. No existe una caracterización de qué **combinaciones** de contaminantes se repiten en la ZMM ni de las condiciones meteorológicas que las acompañan.

Pregunta central. ¿Qué combinaciones típicas de contaminantes (“regímenes diarios”) se presentan en la ZMM entre 2021 y 2025? ¿En qué temporadas y estaciones ocurren? ¿Con qué condiciones meteorológicas se asocian? ¿Qué tan bien distingue la meteorología del día los regímenes de peor calidad del aire?

Los regímenes se construyen **solo con contaminantes**; la meteorología se usa después para caracterizarlos y discriminarlos.

Objetivos:

- **O1 (esta etapa).** Construir una base estación-día depurada y documentada, que reporte por variable el porcentaje de datos faltantes, invalidados e imputados.
- **O2.** Identificar entre tres y seis regímenes con componentes principales y conglomerados, y evaluar su estabilidad entre periodos con el Índice de Rand Ajustado.
- **O3.** Cuantificar la frecuencia de cada régimen por temporada y estación, y la proporción de días que rebasan los límites de PM10, PM2.5 y O3.
- **O4.** Evaluar, con análisis discriminante, si la meteorología observada del mismo día clasifica los regímenes mejor que una referencia basada solo en la temporada. Se entrena con 2021–2023 y se prueba con 2024–2025.
- **O5.** Implementar una interfaz que muestre la clasificación y su desempeño en los datos de prueba.

1.7 Justificación

En la literatura revisada no encontramos, para la ZMM, un análisis que agrupe días según la combinación conjunta de contaminantes con datos horarios de toda la red. Tampoco encontramos uno que evalúe qué tan bien la meteorología distingue esos tipos de día.

Proponemos un procedimiento que se apoya en tres antecedentes:

- el enfoque de regímenes de Elmourssi et al. (2026);
- la secuencia de técnicas de Mohd Shafi'i y Juahir (2024);
- la validación temporal de Hernandez-Santiago et al. (2026).

El aporte para SIMA es resumir seis contaminantes en pocos tipos de día que se puedan comunicar. Además, si la meteorología observada los distingue bien, la clasificación podría combinarse en el futuro con pronósticos meteorológicos para anticipar episodios. Usar la meteorología observada del mismo día no demuestra por sí solo capacidad de pronóstico.

1.8 Fuentes de datos

Usamos seis libros Excel proporcionados por SIMA (2020–2025), con mediciones horarias de 15 estaciones. Los complementamos con tres documentos del socio:

- *Etiquetas.xlsx*, con unidades, estaciones y banderas;
- *Rangos de los parámetros del SIMA*;
- *Ubicación de las estaciones de monitoreo*.

Los originales no se modificaron y su integridad se verificó con huellas MD5.

Parte II. Comprensión y preparación de los datos

2.1 Importación y estructura

Importamos en R las 87 hojas (una por estación y año) conservando la estación, el año y la fila de origen, y unificamos la columna de fecha, que se llama Fecha y hora en 2020–2024 y date en 2025 (Tabla 1). La base tiene 754 603 registros y 16 columnas.

Características encontradas:

- **Resolución horaria** (99.98 % de saltos de 1 h), aunque Etiquetas.xlsx menciona “promedios diarios”.
- Fechas sin zona horaria y sin cambio de horario visible. Las tratamos como hora local fija, pendiente de confirmar con SIMA.
- Sin duplicados.
- **Sin celdas no numéricas ni banderas de validez:** una celda vacía no indica la causa del faltante.
- **8 189 horas sin registro** (1.07 % de 762 792 esperadas). La mayoría corresponde a la estación NO3, que inicia en diciembre de 2022.

El diccionario completo está en el Anexo A.

Tabla 1: Dimensiones de las bases limpias (SIMA, 2020–2025).

Concepto	Base horaria	Base diaria
Registros (estación-hora / estación-día)	762,792	31,783
de ellos, con fila en los Excel originales	754,603	—
Columnas	39	40
Estaciones	15	15
Hojas estación-año en los Excel	87	87
Variables medidas	15	15
Periodo	2020-01-01 a 2025-12-31	2020-01-01 a 2025-12-31
Estación-días 2021–2025 (periodo de modelado)	—	27,025

2.2 Calidad de los datos

Faltantes. Sobre 762 792 horas esperadas por variable, el faltante original va de 4.7 % (radiación solar) a 26.0 % (PM2.5) (Figura 1). Se concentra en 2020 y en las estaciones NE3 y NO3, que casi no miden PM2.5.




Figura 1: % de horas sin dato tras la limpieza, por variable y estación (base horaria publicada; NO3 empieza en diciembre de 2022 y NE3 casi no mide PM2.5).

Rangos. Los contaminantes casi nunca violan los rangos de operación de SIMA ($\leq 0.05\%$). En la meteorología, esos rangos resultaron inadecuados como criterio de error:

- marcarían heladas reales de invierno;
- marcarían 1.1 % de las horas de presión, concentradas en las estaciones de mayor altitud, porque el rango es único para toda la red.

Consistencia.

- **PM2.5 > PM10:** solo 37 de 555 259 horas, lo que indica una depuración previa de SIMA.
- **NOX $\neq$ NO + NO2:** en 11.4 % de las horas de NE3 y 8.2 % de NTE2, frente a menos de 2 % en el resto.
- **Temperatura:** 1 082 lecturas se apartan más de 10 °C de la mediana de la red a la misma hora. Incluyen 25 horas en el límite del sensor (−50 °C) y valores bajo cero en verano.

Un cuaderno reproducible de auditoría documenta cada hallazgo (notebooks/01_auditoria_datos_crudos.qmd).

2.3 Selección de datos y variables

Periodo. Conservamos 2020 en la base publicada, pero lo excluimos del modelado por su baja cobertura y por el efecto atípico del confinamiento (Schiavo et al., 2023). El periodo de análisis es 2021–2025.

Variables.

- **Activas** (definen los regímenes): PM10 y PM2.5 (24 h), O3 (máximo diario del promedio móvil de 8 h), NO2, CO y SO2.

- **Meteorológicas:** temperatura, humedad, radiación, presión, viento y lluvia. Caracterizan los regímenes y sirven como predictoras en el discriminante.
- **Excluidas:** NO y NOX, por redundantes con NO2.

Registros. Entran los días completos en todas esas variables (núcleo B). Excluimos las estaciones NE3 y NO3, que casi no miden PM2.5. Quedan **14 398 días-estación de 13 estaciones** (60.7 % de sus días entre 2021 y 2025), entre 28.0 % (NTE) y 81.5 % (SE3) por estación.

La proporción de días retenidos es similar por temporada (59.2–61.5 %). Esto reduce, pero no descarta, un sesgo de selección: los faltantes podrían concentrarse en condiciones particulares.

Como sensibilidad conservamos un núcleo sin PM2.5 (Anexo C).

2.4 Limpieza

Sobre los datos horarios anulamos valores (NA con bandera), **sin eliminar filas**, cuando se cumplía alguno de estos criterios:

1. **Fuera de rango.** En contaminantes, el rango de operación del año; en meteorología, el del fabricante; en lluvia, el máximo de operación.
2. **Salto de más de 10 °C o 10 mm Hg en una hora.**
3. **PM2.5 > PM10**, siguiendo las banderas de SIMA.
4. **Rachas de 24 h o más con valores idénticos.**
5. **Consistencia espacial.** Temperatura con desviación mayor de 10 °C, o humedad mayor de 40 puntos, respecto de la mediana de la red a la misma hora, cuando reportan al menos cinco estaciones. También las lecturas en el límite del sensor.

La prueba espacial es habitual en el control de calidad meteorológico (Fiebrich et al., 2010). Una lectura atípica es sospechosa, no necesariamente errónea; por eso los umbrales son una decisión del equipo, justificada por la distribución de las desviaciones y por la plausibilidad física.

Los extremos dentro de rango se conservaron, porque pueden ser episodios reales (Hernández-Romero et al., 2026). En total se anuló como máximo 0.82 % de las horas de una variable (NO).

Imputación. Usamos interpolación lineal en huecos de hasta 3 h, por estación y variable (Moritz & Bartz-Beielstein, 2017). No imputamos la lluvia ni las horas anuladas por la prueba espacial. Después volvimos a validar los valores imputados y revertimos los que violaban alguna regla: 3 599 en PM2.5, 252 en PM10, 54 en presión y 5 en humedad.

El imputado neto fue de 0 % a 2.88 % (PM2.5) y el faltante final quedó entre 4.5 % y 23.2 % (Tabla 2). Un script valida automáticamente la base publicada, y dos revisiones independientes reprodujeron exactamente los CSV.

Tabla 2: Limpieza por variable, como % de 762,792 horas estación (87 hojas-año). Invalidado = fuera de rango, notas del PDF, saturación, saltos, PM2.5 > PM10, consistencia espacial (TOUT, RH) y rachas ≥ 24 h; final = original + invalidado – imputado. viento_uv = componentes u/v.

Variable	% faltante original	% invalidado	% imputado	% faltante final
CO	14.2	0.02	0.60	13.7
NO	17.6	0.82	1.80	16.7
NO2	18.3	0.67	1.18	17.7
NOX	17.7	0.19	1.17	16.7
O3	15.6	0.00	1.20	14.4
PM10	5.7	0.01	0.95	4.7

PM2.5	26.0	0.02	2.88	23.2
PRS	6.1	0.41	0.80	5.7
RAINF	5.8	0.00	0.00	5.8
RH	12.3	0.58	0.61	12.3
SO2	15.9	0.00	2.25	13.7
SR	4.7	0.14	0.34	4.5
TOUT	7.9	0.19	0.62	7.5
WSR	7.9	0.01	0.00	7.9
WDR	9.3	0.00	0.00	9.3
viento_uv	12.5	0.01	1.08	11.4

2.5 Transformación y preparación

- **Agregación diaria.** Un valor diario es válido con al menos 18 horas válidas, el criterio del 75 % de SIMA.
- **Viento.** Lo convertimos a m/s y a componentes u y v, porque la dirección es una variable circular.
- **Lluvia.** Como su unidad no está confirmada, la resumimos como horas con lluvia y un indicador 0/1.
- **Atributos derivados:** temporada (seca-fría, nov–feb; seca-cálida, mar–may; cálida-húmeda, jun–oct; definición operativa del equipo) e indicador del confinamiento de 2020.
- **No discretizamos concentraciones.** La estandarización se aplicará al modelar, ajustada solo con los datos de entrenamiento.

Base limpia (CSV horarios por año, CSV diario, diccionario y scripts): <https://github.com/Leo-issacs/reto-sima-multivariados/tree/main/data/clean> (versión datos -v1.1).

Declaratoria de uso de IA (Opción B)

- **Herramientas:** Claude (Anthropic): Claude Opus y Claude Code; ChatGPT y Codex (OpenAI).
- **Uso realizado:**
 - Codex: preparación del entorno y revisión independiente del código y de los datos.
 - Claude Opus: planeación, búsqueda de literatura, decisiones de limpieza propuestas e integración y edición del texto.
 - Claude Code: scripts de R de importación, diagnóstico, limpieza y validación.
 - Claude y ChatGPT, usados por integrantes del equipo: borradores de 1.1–1.4 y fichas de lectura, a partir de los PDF de las fuentes.
- **Secciones:** Partes I y II, scripts en scripts/ y R/ y cuaderno de auditoría.
- **Validación realizada por los estudiantes:** [COMPLETAR por el equipo con lo realmente revisado].
- Confirmamos que revisamos y verificamos el contenido final y asumimos la responsabilidad sobre él.

Referencias

Aguirre-López, M. A., Rodríguez-González, M. A., Soto-Villalobos, R., Gómez-Sánchez, L. E., Benavides-Ríos, Á. G., Benavides-Bravo, F. G., Walle-García, O., & Pamanés-Aguilar, M. G. (2022). Statistical analysis of PM10 concentration in the Monterrey Metropolitan Area, Mexico (2010–2018). *Atmosphere*, 13(2), 297. <https://doi.org/10.3390/atmos13020297>

Elmourssi, D. M., El-Assy, A. M., & Amer, H. M. (2026). Clustering and machine learning techniques identify air pollution regimes in Greater Cairo. *Scientific Reports*. <https://doi.org/10.1038/s41598-026-49777-5>

Fiebrich, C. A., Morgan, C. R., McCombs, A. G., Hall, P. K., & McPherson, R. A. (2010). Quality assurance procedures for mesoscale meteorological data. *Journal of Atmospheric and Oceanic Technology*, 27(10), 1565–1582. <https://doi.org/10.1175/2010JTECHA1433.1>

Hernández-Romero, K., Hernández-Romero, I. M., Mendoza, A., Pérez-Rodríguez, M., Barajas-Villarruel, L. R., Medellín-Carrillo, S., & González, L. T. (2026). Persistent air pollution regimes and regulatory exceedances of PM₁₀, PM_{2.5}, and O₃ in the Monterrey Metropolitan Area, Mexico. *City and Environment Interactions*, 31, 100410. <https://doi.org/10.1016/j.cacint.2026.100410>

Hernandez-Santiago, E., Tello-Leal, E., Jaramillo-Perez, J. M., & Macías-Hernández, B. A. (2026). Development of an ozone (O₃) predictive emissions model using the XGBoost machine learning algorithm. *Big Data and Cognitive Computing*, 10(1), 15. <https://doi.org/10.3390/bdcc10010015>

Martínez-Cinco, M. A., Santos-Guzmán, J., & Mejía-Velázquez, G. M. (2016). Source apportionment of PM_{2.5} for supporting control strategies in the Monterrey Metropolitan Area, Mexico. *Journal of the Air & Waste Management Association*, 66(6), 631–642. <https://doi.org/10.1080/10962247.2016.1159259>

Mohd Shafi'i, M. S., & Juahir, H. (2024). Assessment of spatial air quality on the East Coast of Peninsular Malaysia utilizing environmetric techniques. *Environmental Monitoring and Assessment*, 196(7), 640. <https://doi.org/10.1007/s10661-024-12787-9>

Moritz, S., & Bartz-Beielstein, T. (2017). imputeTS: Time series missing value imputation in R. *The R Journal*, 9(1), 207–218. <https://doi.org/10.32614/RJ-2017-009>

Orellano, P., Reynoso, J., Quaranta, N., Bardach, A., & Ciapponi, A. (2020). Short-term exposure to particulate matter (PM₁₀ and PM_{2.5}), nitrogen dioxide (NO₂), and ozone (O₃) and all-cause and cause-specific mortality: Systematic review and meta-analysis. *Environment International*, 142, 105876. <https://doi.org/10.1016/j.envint.2020.105876>

Ramírez-Velarde, R., Esquivel-Flores, O., & Mejía-Velázquez, G. (2024). Forecasting air pollution contingencies using predictive analytic techniques. *Atmosphere*, 15(11), 1271. <https://doi.org/10.3390/atmos15111271>

Schiavo, B., Morton-Bermea, O., Arredondo-Palacios, T. E., Meza-Figueroa, D., Robles-Morua, A., García-Martínez, R., Valera-Fernández, D., Inguaggiato, C., & Gonzalez-Grijalva, B. (2023). Analysis of COVID-19 lockdown effects on urban air quality: A case study of Monterrey, Mexico. *Sustainability*, 15(1), 642. <https://doi.org/10.3390/su15010642>

Secretaría de Medio Ambiente del Estado de Nuevo León & Clean Air Institute. (2024). *Plan Integral de Gestión Estratégica de la Calidad del Aire 2023–2033 (PIGECA)*. Gobierno del Estado de Nuevo León. http://aire.nl.gob.mx/docs/reportes/PIGECA_2023_2033.pdf

SEMARNAT. (2024, 25 de enero). NOM-172-SEMARNAT-2023, Lineamientos para la obtención y comunicación del índice de calidad del aire y riesgos a la salud. *Diario Oficial de la Federación*.

Sistema Integral de Monitoreo Ambiental [SIMA]. (2026, 14 de agosto). *Red de monitoreo y manejo de datos de calidad del aire* [Presentación de diapositivas]. Gobierno de Nuevo León.

World Health Organization. (2021). *WHO global air quality guidelines: Particulate matter (PM_{2.5} and PM₁₀), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide*. <https://www.who.int/publications/i/item/9789240034228>

Anexos

Anexo A. Diccionario de datos

Tabla 3: Diccionario completo de las bases publicadas en data/clean/.

Base	Columna	Tipo	Unidad	Descripción	Fuente o regla
horario	estacion	texto		Código de hoja/estación SIMA (ver data/metadatos/estaciones.csv). NO2 y SO2 son estaciones, no variables	Nombre de la hoja del Excel
horario	fecha_hora	texto AAAA-MM-DD HH:MM:SS	hora local	Marca horaria (00:00 a 23:00). Hora local ingenua sin zona; sin cambio de horario visible. Confirmar con SIMA	Excel BD AAAA
horario	confinamiento_2020	0/1		1 entre 2020-04-01 y 2020-05-31 (incluye ambos días), 0 en el resto	Definición del equipo
horario	CO	numérico	ppm	Monóxido de carbono. Vacío = sin valor válido tras la limpieza. Contaminantes: rango de operación del año; meteorología: rango del fabricante; interpolado si f_ _l = I; una imputación que incumple una regla se revierte a vacío, f_ _l = X	Excel BD AAAA + reglas de scripts/03_limpiar. R
horario	NO	numérico	ppb	Monóxido de nitrógeno. Vacío = sin valor válido tras la limpieza. Contaminantes: rango de operación del año; meteorología: rango del fabricante; interpolado si f_ _l = I; una imputación que incumple una regla se revierte a vacío, f_ _l = X	Excel BD AAAA + reglas de scripts/03_limpiar. R
horario	NO2	numérico	ppb	Dióxido de nitrógeno. Vacío = sin valor válido tras la limpieza. Contaminantes: rango de operación del año; meteorología: rango del fabricante; interpolado si f_ _l = I; una imputación que incumple una regla se revierte a vacío, f_ _l = X	Excel BD AAAA + reglas de scripts/03_limpiar. R
horario	NOX	numérico	ppb	Óxidos de nitrógeno (NO + NO2). Vacío = sin valor válido tras la limpieza. Contaminantes: rango de operación del año; meteorología: rango del fabricante; interpolado si f_ _l = I; una imputación que incumple una regla se revierte a vacío, f_ _l = X	Excel BD AAAA + reglas de scripts/03_limpiar. R
horario	O3	numérico	ppb	Ozono. Vacío = sin valor válido tras la limpieza. Contaminantes: rango de operación del año; meteorología: rango del fabricante; interpolado si f_ _l = I; una imputación que incumple una regla se revierte a vacío, f_ _l = X	Excel BD AAAA + reglas de scripts/03_limpiar. R
horario	PM10	numérico	ug/m3	Material particulado < 10 µm. Vacío = sin valor válido tras la limpieza. Contaminantes: rango de operación del año; meteorología: rango del fabricante; interpolado si f_ _l = I; una imputación que incumple una regla se revierte a vacío, f_ _l = X	Excel BD AAAA + reglas de scripts/03_limpiar. R
horario	PM2.5	numérico	ug/m3	Material particulado < 2.5 µm. Vacío = sin valor válido tras la limpieza. Contaminantes: rango de operación del año; meteorología: rango del fabricante; interpolado si f_ _l = I; una imputación que incumple una regla se revierte a vacío, f_ _l = X	Excel BD AAAA + reglas de scripts/03_limpiar. R
horario	PRS	numérico	mm Hg	Presión atmosférica. Vacío = sin valor válido tras la limpieza. Contaminantes: rango de operación del año; meteorología: rango del fabricante;	Excel BD AAAA + reglas de scripts/03_limpiar.

				interpolado si f_ = I; una imputación que incumple una regla se revierte a vacío, f_ = X	R
horario	RAINF	numérico	mm/h	Precipitación, tal como viene en el Excel (sin conversión; la unidad no está confirmada). Se invalida (F) lo que supera el máximo de operación del año. Vacío = sin valor válido	Excel BD AAAA + reglas de scripts/03_limpiar. R
horario	RH	numérico	%	Humedad relativa. Vacío = sin valor válido tras la limpieza. Contaminantes: rango de operación del año; meteorología: rango del fabricante; interpolado si f_ = I; una imputación que incumple una regla se revierte a vacío, f_ = X	Excel BD AAAA + reglas de scripts/03_limpiar. R
horario	SO2	numérico	ppb	Dióxido de azufre. Vacío = sin valor válido tras la limpieza. Contaminantes: rango de operación del año; meteorología: rango del fabricante; interpolado si f_ = I; una imputación que incumple una regla se revierte a vacío, f_ = X	Excel BD AAAA + reglas de scripts/03_limpiar. R
horario	SR	numérico	kW/m2	Radiación solar. Vacío = sin valor válido tras la limpieza. Contaminantes: rango de operación del año; meteorología: rango del fabricante; interpolado si f_ = I; una imputación que incumple una regla se revierte a vacío, f_ = X	Excel BD AAAA + reglas de scripts/03_limpiar. R
horario	TOUT	numérico	°C	Temperatura. Vacío = sin valor válido tras la limpieza. Contaminantes: rango de operación del año; meteorología: rango del fabricante; interpolado si f_ = I; una imputación que incumple una regla se revierte a vacío, f_ = X	Excel BD AAAA + reglas de scripts/03_limpiar. R
horario	WSR	numérico	km/h	Velocidad del viento (validada, sin imputar). Vacío = sin valor válido tras la limpieza. Contaminantes: rango de operación del año; meteorología: rango del fabricante	Excel BD AAAA + reglas de scripts/03_limpiar. R
horario	WDR	numérico	grados	Dirección del viento, grados de donde sopla (validada, sin imputar). Vacío = sin valor válido tras la limpieza. Contaminantes: rango de operación del año; meteorología: rango del fabricante	Excel BD AAAA + reglas de scripts/03_limpiar. R
horario	viento_u	numérico	m/s	Componente este-oeste del viento = - WSR/3.6*sin(WDR). Interpolada si f_uv = I	Derivada de WSR y WDR
horario	viento_v	numérico	m/s	Componente norte-sur del viento = - WSR/3.6*cos(WDR). Interpolada si f_uv = I	Derivada de WSR y WDR
horario	f_CO	texto (1 letra)		Bandera de la hora: V válida original; N falta original; F fuera de rango duro; P regla de las notas del PDF; S salto horario (>10 °C o >10 mm Hg); R PM2.5 > PM10 (se invalidan ambas); K racha >=24 h de valores idénticos invalidada; L lectura de TOUT próxima al límite del instrumento (TOUT >= 49.9), excluida por sospecha de saturación o fallo; E consistencia espacial, no se imputa (TOUT a más de 10 °C o RH a más de 40 pp de la mediana de la red en esa hora, con >= 5 estaciones); C racha >=6 h idéntica marcada y conservada; I imputada (interpolación lineal, hueco <=3 h, revalidada); X imputación revertida (el valor interpolado incumplía rango, salto o PM2.5 <= PM10 y volvió a NA; nunca se modifica un valor original). En horas I o X se pierde el motivo original de invalidez	scripts/03_limpiar. R

horario	f_NO	texto (1 letra)	Bandera de NO (mismos códigos que f_CO)	scripts/03_limpiar.R
horario	f_NO2	texto (1 letra)	Bandera de NO2 (mismos códigos que f_CO)	scripts/03_limpiar.R
horario	f_NOX	texto (1 letra)	Bandera de NOX (mismos códigos que f_CO)	scripts/03_limpiar.R
horario	f_O3	texto (1 letra)	Bandera de O3 (mismos códigos que f_CO)	scripts/03_limpiar.R
horario	f_PM10	texto (1 letra)	Bandera de PM10 (mismos códigos que f_CO)	scripts/03_limpiar.R
horario	f_PM2.5	texto (1 letra)	Bandera de PM2.5 (mismos códigos que f_CO)	scripts/03_limpiar.R
horario	f_PRS	texto (1 letra)	Bandera de PRS (mismos códigos que f_CO)	scripts/03_limpiar.R
horario	f_RAINF	texto (1 letra)	Bandera de RAINF (mismos códigos que f_CO; RAINF no se imputa)	scripts/03_limpiar.R
horario	f_RH	texto (1 letra)	Bandera de RH (mismos códigos que f_CO)	scripts/03_limpiar.R
horario	f_SO2	texto (1 letra)	Bandera de SO2 (mismos códigos que f_CO)	scripts/03_limpiar.R
horario	f_SR	texto (1 letra)	Bandera de SR (mismos códigos que f_CO)	scripts/03_limpiar.R
horario	f_TOUT	texto (1 letra)	Bandera de TOUT (mismos códigos que f_CO)	scripts/03_limpiar.R
horario	f_WSR	texto (1 letra)	Bandera de WSR (mismos códigos que f_CO)	scripts/03_limpiar.R
horario	f_WDR	texto (1 letra)	Bandera de WDR (mismos códigos que f_CO)	scripts/03_limpiar.R
horario	f_uv	texto (1 letra)	Bandera de viento u/v (según WSR y WDR) (mismos códigos que f_CO)	scripts/03_limpiar.R
horario	nox_inconsistente	0/1	Calculada sobre los valores FINALES publicados (después de imputar y revertir): 1 si NOX-(NO+NO2) > max(1 ppb, 10% de NOX); 0 si no; vacío solo si falta alguna de las tres concentraciones. Solo bandera, no invalida. Los diagnósticos con valores solo observados están en output/diagnostico/nox_inconsistencia_por_estacion.csv (columnas_obs)	scripts/03_limpiar.R
horario	f_obs_TOUT	texto (1 letra)	Bandera de TOUT en la etapa observada, antes de imputar (mismos códigos que f_CO, sin I ni X). Conserva la causa de invalidez (p. ej. E o L) aunque la hora se imputara; sirve para comprobar que las horas E/L nunca se imputan	scripts/03_limpiar.R
horario	f_obs_RH	texto (1 letra)	Bandera de RH en la etapa observada, antes de imputar (mismos códigos que f_obs_TOUT)	scripts/03_limpiar.R
diario	estacion	texto	Código de estación	Hoja del Excel
diario	fecha	fecha AAAA-MM-DD	Día calendario local	
diario	anio	entero	Año	
diario	temporada	texto	Temporada regional: seca_fria (nov-feb), seca_calida (mar-may), calida_humeda (jun-oct). Definición operativa del equipo; nombres según Hernández-Romero et al. (2026); cortes según la	Definición del equipo

				climatología del PIGECA 2023-2033 1 entre 2020-04-01 y 2020-05-31	Definición del equipo
diario	confinamiento_2020	0/1			
diario	CO	numérico	ppm	Media diaria de las horas válidas (incluye imputadas); vacío si < 18 h válidas	Agregado de la tabla horaria
diario	NO	numérico	ppb	Media diaria de las horas válidas (incluye imputadas); vacío si < 18 h válidas	Agregado de la tabla horaria
diario	NO2	numérico	ppb	Media diaria de las horas válidas (incluye imputadas); vacío si < 18 h válidas	Agregado de la tabla horaria
diario	NOX	numérico	ppb	Media diaria de las horas válidas (incluye imputadas); vacío si < 18 h válidas	Agregado de la tabla horaria
diario	PM10	numérico	ug/m3	Media diaria de las horas válidas (incluye imputadas); vacío si < 18 h válidas	Agregado de la tabla horaria
diario	PM2.5	numérico	ug/m3	Media diaria de las horas válidas (incluye imputadas); vacío si < 18 h válidas	Agregado de la tabla horaria
diario	SO2	numérico	ppb	Media diaria de las horas válidas (incluye imputadas); vacío si < 18 h válidas	Agregado de la tabla horaria
diario	TOUT	numérico	°C	Media diaria de las horas válidas (incluye imputadas); vacío si < 18 h válidas	Agregado de la tabla horaria
diario	RH	numérico	%	Media diaria de las horas válidas (incluye imputadas); vacío si < 18 h válidas	Agregado de la tabla horaria
diario	SR	numérico	kW/m2	Media diaria de las horas válidas (incluye imputadas); vacío si < 18 h válidas	Agregado de la tabla horaria
diario	PRS	numérico	mm Hg	Media diaria de las horas válidas (incluye imputadas); vacío si < 18 h válidas	Agregado de la tabla horaria
diario	horas_lluvia	entero	horas	Número de horas del día con $0 < \text{RAINF} \leq$ máximo de operación del año; vacío si < 18 h válidas de RAINF. La cantidad de lluvia no se usa porque la unidad no está confirmada	Agregado de la tabla horaria
diario	llovio	0/1		1 si horas_lluvia > 0	Agregado de la tabla horaria
diario	O3_max8h	numérico	ppb	Máximo diario del promedio móvil de 8 h (ventana por hora inicial, ≥ 6 de 8 horas válidas); vacío si < 18 h válidas de O3 en el día	Agregado de la tabla horaria
diario	viento_u	numérico	m/s	Media diaria de la componente u; vacío si < 18 h válidas	Agregado de la tabla horaria
diario	viento_v	numérico	m/s	Media diaria de la componente v	Agregado de la tabla horaria
diario	viento_rapidez_ms	numérico	m/s	Media diaria de la rapidez horaria $\sqrt{u^2+v^2}$	Agregado de la tabla horaria
diario	n_horas_	entero	horas	Número de horas válidas (incluye imputadas) del día para esa variable; n_horas_viento cuenta horas con u/v; n_horas_O3_max8h cuenta horas de O3	Agregado de la tabla horaria
diario	n_horas_nox_inconsistente	entero	horas	Horas del día con nox_inconsistente = 1 (bandera final)	Agregado de la tabla horaria
diario	en_nucleo_A	0/1		1 si el estación-día está completo en el núcleo A: PM10, O3_max8h, NO2, CO, SO2, TOUT, RH, SR, viento (u/v), PRS y horas_lluvia con ≥ 18 h válidas. Núcleo de sensibilidad	scripts/O3_limpiar. R
diario	en_nucleo_B	0/1		1 si el estación-día está completo en el núcleo B = A + PM2.5. Conjunto principal de modelado	scripts/O3_limpiar. R
diario	en_periodo_modelado	0/1		1 si el año está entre 2021 y 2025	Decisión del equipo

cobertura	estacion, anio			Hoja-año	
cobertura	variable	texto		Variable diaria evaluada (viento_uv = u/v; O3 = máximo de 8 h; RAINF = suma diaria)	
cobertura	dias_totales, dias_validos	entero	días	Días del año de la hoja-año y días con >= 18 h válidas de esa variable	
cobertura	pct_dias_validos	numérico	%	100*dias_validos/dias_totales	
cobertura	cobertura_baja	0/1		1 si pct_dias_validos < 75	Criterio del 75 % de SIMA
informe	variable	texto		Variable (viento_uv = u/v)	
informe	horas_esperadas	entero	horas	Denominador: horas de la malla completa de todas las hojas-año (24 x días del año), incluidas las horas sin fila en el Excel	
informe	*_n / *_pct	entero / %		Horas y % sobre horas_esperadas por categoría: faltante_original, invalidada_F/P/L/S/R/E/K, marcada_C (informativa), imputada_bruta (I + X), imputacion_revertida (X), imputada (neta = I, tras revertir) y faltante_final (= invalidadas y faltantes - imputadas netas)	

Anexo B. Rangos de operación y del fabricante

Tabla 4: Rangos de operación por año (Rangos de los parámetros del SIMA) y rango del fabricante. Unidades: ver Anexo A.

Variable	2020	2021	2022	2023	2024	2025	Fabricante
PM10	0–800	0–800	0–999	0–900	0–999	0–820	0–1000
PM2.5	0–205.94	0–325	0–450	0–800	0–999	0–350	0–1000
O3	0–153	0–175	0–160	0–175	0–180	0–185	0–1000
NO	0–500	0–350	0–400	0–500	0–400	0–350	0–500
NO2	0–200	0–100	0–175	0–175	0–130	0–175	0–500
NOX	0–500	0–400	0–420	0–500	0–500	0–400	0–500
SO2	0–200	0–300	0–200	0–250	0–150	0–405	0–500
CO	0–20	0–10	0–8	0–14	0–18	0–10	0–50
RH	0–100	0–100	0–100	0–100	0–100	0–100	0–100
WSR	0–75	0–40	0–35	0–40	0–38	0–40	0–180
TOUT	0–41	-6.5–45	-5–45	0–45	-4–45.5	-4.5–45	-50–50
SR	0–1	0–1	0–1.25	0–1	0–1.26	0–1.2	0–1.4
PRS	690–750	690–740	700–740	690–740	687.5–740	688–740	449.9–824.9
WDR	0–360	0–360	0–360	0–360	0–360	0–360	0–360
RAINF	0–30	0–80	0–25	0–70	0–50	0–25	—

Notas del PDF: 2020 O3: Omitir máximo de NTE2; 2020 WSR: No considerar valor por arriba de 75 km/h.; 2020 SR: No considerar lecturas por encima de este rango.; 2020 PRS: No considerar valores fuera del rango.; 2021 NO: No considerar valor por encima del límite máximo.; 2021 NO2: No considerar valores menores.; 2021 SR: No considerar lecturas por encima de este rango.

Anexo C. Núcleos de modelado y cobertura por hoja-año




Figura 2: Estación-días completos por año en el núcleo A (PM10, O3 máx. 8 h, NO2, CO, SO2, TOUT, RH, SR, viento, PRS, RAINF) y en el núcleo B (A + PM2.5). Etiqueta: días completos (% de los días estación del año). Total de días estación: 2020: 4,758; 2021: 5,110; 2022: 5,475; 2023: 5,475; 2024: 5,490; 2025: 5,475. El 2020 se conserva en los datos, pero no entra al modelado.

Tabla 5: Porcentaje de días con al menos 18 h válidas, por hoja-año y variable. Un asterisco marca cobertura baja (menos de 75 %). u/v = componentes del viento.

Est.	Año	PM10	PM2.5	O3	NO2	NO	NOX	CO	SO2	TOUT	RH	SR	PRS	RAINF	u/v
CE	2020	94	74*	82	87	87	87	98	98	98	98	98	98	98	98
CE	2021	96	90	87	79	80	79	92	92	97	97	97	97	97	97
CE	2022	98	89	97	98	98	98	98	97	98	97	99	98	98	98
CE	2023	96	87	96	97	97	97	96	97	97	97	99	97	97	97
CE	2024	97	80	95	96	96	96	97	97	97	97	98	97	97	97
CE	2025	99	84	97	95	88	95	76	97	97	96	100	97	97	97
NE	2020	93	90	0*	0*	15*	0*	53*	12*	78	76	88	78	82	37*
NE	2021	99	98	85	85	86	85	97	76	100	99	99	100	100	75
NE	2022	99	95	97	99	99	99	99	99	99	98	100	99	99	99
NE	2023	96	91	94	98	98	98	94	98	98	96	99	97	98	98
NE	2024	97	92	96	98	98	98	98	98	56*	97	98	96	98	98
NE	2025	95	92	89	86	86	86	88	89	7*	95	97	95	96	94
NE2	2020	89	70*	11*	2*	2*	6*	67*	56*	96	96	99	96	96	44*
NE2	2021	92	91	81	80	81	80	91	93	96	96	100	96	97	72*
NE2	2022	98	97	99	98	99	99	99	97	99	99	100	99	99	72*
NE2	2023	95	93	92	98	98	98	92	97	98	91	98	98	98	98
NE2	2024	94	61*	93	96	96	96	82	96	96	96	99	94	96	96
NE2	2025	95	4*	94	57*	56*	58*	74*	97	96	96	100	96	98	93
NE3	2021	95	0*	95	94	94	94	92	89	95	95	92	94	95	90
NE3	2022	93	0*	98	97	97	97	97	80	98	97	80	94	97	92
NE3	2023	96	0*	96	94	94	94	98	93	99	99	84	97	99	99
NE3	2024	95	0*	95	94	94	94	94	6*	96	96	83	96	96	96
NE3	2025	96	27*	94	84	84	84	76	45*	98	98	87	96	97	97

NO	2020	96	96	0*	15*	36*	16*	5*	22*	98	98	98	98	98	57*
NO	2021	86	85	80	94	97	94	80	97	98	92	98	98	98	78
NO	2022	94	78	94	85	84	84	95	93	94	92	100	94	98	94
NO	2023	96	47*	93	96	96	96	96	96	96	94	97	96	96	96
NO	2024	90	14*	85	73*	74*	74*	63*	88	44*	44*	92	90	90	90
NO	2025	99	3*	92	88	87	85	92	92	89	89	98	96	96	96
NO2	2020	97	82	75*	60*	87	87	99	87	99	98	100	99	99	67*
NO2	2021	96	96	96	97	97	97	97	83	93	93	99	89	97	73*
NO2	2022	99	92	99	99	99	99	96	89	100	87	75*	93	100	100
NO2	2023	99	87	98	100	100	100	98	98	99	98	60*	100	100	100
NO2	2024	97	68*	96	97	97	97	97	97	97	96	54*	97	97	97
NO2	2025	99	82	95	70*	69*	70*	97	97	99	99	72*	100	100	100
NO3	2022	8*	0*	8*	8*	8*	8*	8*	8*	8*	7*	8*	8*	8*	7*
NO3	2023	95	0*	83	85	85	85	82	86	100	10*	100	100	100	77
NO3	2024	98	24*	97	86	86	86	87	100	100	93	99	100	100	99
NO3	2025	71*	13*	70*	41*	41*	41*	71*	71*	71*	70*	96	71*	71*	97
NTE	2020	74*	66*	0*	0*	0*	0*	0*	0*	10*	10*	92	10*	30*	11*
NTE	2021	93	82	82	69*	69*	69*	73*	74*	74*	62*	96	74*	74*	74*
NTE	2022	94	85	97	100	100	100	100	100	100	88	92	100	100	100
NTE	2023	93	91	94	96	96	96	94	93	97	50*	89	96	97	92
NTE	2024	96	97	97	99	99	99	99	99	99	4*	84	96	99	99
NTE	2025	97	85	96	99	99	99	98	77	98	0*	71*	98	98	99
NTE2	2020	90	58*	6*	18*	20*	18*	75	26*	98	98	99	98	98	98
NTE2	2021	94	96	90	78	78	78	98	31*	98	98	100	98	98	98
NTE2	2022	99	98	99	100	100	100	100	99	100	99	100	99	100	100
NTE2	2023	98	94	98	100	100	100	97	100	100	99	100	100	100	100
NTE2	2024	98	96	94	99	99	99	98	99	99	98	100	99	99	99
NTE2	2025	97	96	96	98	98	98	98	98	98	98	100	98	98	98
SE	2020	93	90	92	0*	0*	0*	87	92	90	98	99	82	98	4*
SE	2021	94	92	94	78	68*	78	95	95	57*	96	99	89	96	72*
SE	2022	99	96	98	100	100	100	100	99	100	100	100	100	100	100
SE	2023	99	78	98	100	100	100	99	99	100	99	100	100	100	100
SE	2024	96	73*	98	99	99	99	88	99	99	99	100	99	99	99
SE	2025	97	86	97	96	96	96	71*	96	96	96	99	96	96	96
SE2	2020	89	67*	0*	10*	10*	10*	0*	91	81	0*	100	81	13*	79
SE2	2021	90	86	60*	72*	72*	72*	86	85	93	70*	98	93	74*	88
SE2	2022	95	89	94	95	95	95	92	95	95	95	98	95	100	95
SE2	2023	100	96	100	100	100	100	88	100	100	99	100	99	100	94
SE2	2024	96	98	90	93	96	96	86	96	98	98	100	98	100	98
SE2	2025	96	99	90	97	97	97	78	97	98	73*	99	97	99	98
SE3	2020	93	86	71*	99	99	99	89	87	99	99	100	87	99	99
SE3	2021	91	86	94	90	90	90	94	88	94	91	100	94	93	94
SE3	2022	98	96	98	98	98	98	96	98	98	98	100	98	98	98
SE3	2023	96	96	94	97	97	97	94	97	97	97	99	97	97	96
SE3	2024	99	96	100	98	98	98	86	100	100	99	100	99	100	100
SE3	2025	98	82	100	99	99	99	90	99	99	98	95	99	99	98
SO	2020	98	94	69*	1*	20*	36*	50*	75	100	99	100	89	100	84
SO	2021	94	95	94	78	78	86	89	96	93	95	94	92	96	91
SO	2022	97	93	96	97	97	97	88	97	97	97	98	97	97	97
SO	2023	100	94	96	97	98	97	100	100	100	100	99	99	100	99

SO	2024	96	79	95	97	97	97	97	97	97	93	97	93	97	96
SO	2025	98	81	96	94	92	92	95	98	88	24*	97	89	89	88
SO2	2020	90	80	98	52*	49*	52*	100	77	100	100	100	100	100	28*
SO2	2021	94	84	99	90	90	90	87	82	99	99	100	99	99	75*
SO2	2022	97	98	98	99	99	99	98	98	99	97	100	99	99	93
SO2	2023	95	96	99	99	99	99	98	100	100	99	100	100	100	100
SO2	2024	94	95	99	100	100	100	100	100	100	98	100	100	100	100
SO2	2025	95	81	99	100	100	100	86	100	100	99	100	100	100	100
SUR	2020	95	38*	0*	0*	0*	2*	3*	0*	100	100	100	100	100	11*
SUR	2021	95	66*	84	82	82	82	91	75	98	98	99	98	98	74*
SUR	2022	99	85	97	99	99	99	97	94	99	99	99	99	99	99
SUR	2023	99	80	98	96	96	96	97	100	96	97	100	96	100	100
SUR	2024	99	79	100	96	97	98	87	100	92	93	100	92	100	100
SUR	2025	98	81	100	94	94	94	93	96	86	86	97	86	93	93