Reto SIMA: calidad del aire en el Área Metropolitana de Monterrey

Etapa 2. Conociendo los datos

Leonardo Orozco · Pablo Alonso Robles Nava · Daniel Ayala · Ignacio Kume

8 de octubre de 2026

Análisis multivariado (MA2003B) · Grupo 201 · Equipo 1

Repositorio de GitHub: https://github.com/Leo-issacs/reto-sima-multivariados

1. Objetivo de indagación

En la etapa 1 propusimos identificar regímenes multicontaminante mediante conglomerados. Tras la retroalimentación de los profesores, acotamos el objetivo a PM2.5 para completar el análisis en las tres semanas restantes. Conservamos el periodo 2021–2025 y las temporadas definidas, y actualizamos la limpieza con los hallazgos de esta etapa. La elección de PM2.5 se apoya en la evidencia de su asociación con mortalidad por exposición de corto plazo (Orellano et al., 2020; World Health Organization [WHO], 2021) y en los episodios documentados en la ZMM (Hernández-Romero et al., 2026).

Pregunta. ¿En qué medida la meteorología del día mejora la clasificación retrospectiva de los días-estación con PM2.5 promedio de 24 h superior a 25 µg/m³, respecto de un modelo que solo considera la estación de monitoreo y la temporada, en 13 estaciones de la ZMM durante 2021–2025?

Objetivo general. Comparar mediante validación temporal dos modelos de análisis discriminante lineal (LDA): M0, con estación y temporada, y M1, que añade ocho variables meteorológicas. Se evaluarán la diferencia de AUC (ΔAUC) y de exactitud balanceada, con incertidumbre estimada por bootstrap. **Objetivos específicos:** describir las superaciones y sus diferencias meteorológicas en esta etapa; estimar M0, M1 y su diferencia de desempeño en la etapa 3.

Sobre el umbral. 25 µg/m³ es el límite de 24 h del quinto año de aplicación de la NOM-025-SSA1-2021 (Secretaría de Salud, 2021). Lo usamos como referencia fija para todo el periodo, no como evaluación del cumplimiento histórico, porque los límites vigentes cambiaron entre 2021 y 2025. El resultado describe concentraciones, no riesgo individual: por debajo de 25 µg/m³ el riesgo no es nulo (WHO, 2021).

2. Ruta de análisis

El protocolo (`docs/etapa2/protocolo.md`, v3) fija la comparación antes del ajuste definitivo. Declara una prueba preliminar que ya utilizó 2024–2025; por ello, estos años no constituyen una evaluación completamente ajena a la exploración previa. Las decisiones restantes se tomarán con validación progresiva en 2021–2023. La Tabla 1 resume la ruta.

Tabla 1: Ruta de análisis.

Técnica (etapa)	Rol	Justificación
Proporciones, SMD y Spearman (2)	Describir superaciones y asociaciones	Diferencias estandarizadas y asociaciones monotónicas (Austin, 2009)
Componentes principales (3)	Explorar la estructura meteorológica	Resume correlaciones; no garantiza separar clases
LDA, M0 frente a M1 (3)	Técnica principal	Precedente ambiental y supuestos por revisar (Mohd Shafi'i & Juahir, 2024; Johnson & Wichern, 2007)
Regresión logística (3)	Solo robustez	Verifica que la conclusión no dependa del LDA
Validación temporal y bootstrap de 14 días (3)	Desempeño fuera de muestra e incertidumbre	Entrenar 2021–2023; evaluar 2024–2025. Remuestrear bloques con todas las estaciones

Variables. La respuesta binaria `supera_25` indica si el PM2.5 diario supera 25 µg/m³. M0 incluye dos variables categóricas: estación (13 categorías) y temporada, definida como seca-fría (nov–feb), seca-cálida (mar–may) y cálida-húmeda (jun–oct). M1 añade temperatura (TOUT, °C), humedad relativa (RH, %), radiación solar (SR, kW/m²), presión (PRS, mm Hg), componentes *u* y *v* y rapidez del viento (m/s), y número de horas con lluvia (0–24). Las primeras siete son cuantitativas continuas; la última es un conteo. El año define la partición temporal. Los demás contaminantes quedan fuera para centrar la comparación en la meteorología; *u* y *v* representan la dirección del viento sin discontinuidad angular. No usamos la cantidad de lluvia porque su unidad no está confirmada.

3. Datos y papel de la estación

Cada registro corresponde a una estación en un día. Partimos de una base diaria de 31 783 registros y 40 columnas (2020–2025). Para el análisis seleccionamos 2021–2025 y excluimos NE3 y NO3 por su escasa cobertura de PM2.5. Exigimos al menos 18 horas válidas por variable, incluidas las imputadas. De 23 738 registros candidatos quedan 15 390 (64.8 %), sin faltantes en la respuesta ni en los ocho predictores. Se excluyen 3 820 por PM2.5 y 5 763 por meteorología; 1 235 incumplen ambos requisitos y están contados en los dos grupos (Anexo A1). En respuesta a la retroalimentación de la etapa 1, el Anexo C presenta el diccionario completo de las bases horaria (39 columnas), diaria (40) y de la muestra (24), con tipo, dominio y porcentaje de nulos antes y después de la limpieza.

La estación permite representar diferencias persistentes entre sitios, sin identificar por separado sus causas. La presión media varía de unos 701 a 731 mm Hg; por ello también examinamos desviaciones respecto de la media de cada estación y temporada. La retención va de 28.0 % en NO2 a 95.5 % en NTE2. Aquí NO2 es el código de una estación, no el contaminante NO2. Exigir meteorología completa cambia poco la proporción global de superaciones de PM2.5 (25.7 % a 26.3 %), pero en esa estación la reduce de 18.2 % a 10.0 %. Entre sus días con PM2.5 válido, la proporción es 24.6 % sin radiación válida y 8.5 % con ella. Esta selección motiva evaluar M0 también en los 19 918 registros con solo PM2.5 válido.

Hallazgo de calidad y regla nueva. Detectamos lecturas sospechosas: promedios diarios de viento de hasta 33 m/s en SO2 y NE2 (2021), cuando la mediana horaria de la red rondaba 10 km/h, y radiación solar de hasta 1.4 kW/m² entre las 00 y las 04 h, sobre todo en NO2, SE3 y CE. La regla D15 añade pruebas de consistencia inspiradas en Estévez et al. (2011) y Fiebrich et al. (2010), con umbrales elegidos por el equipo: se invalida la radiación de todo el día si su media entre 00 y 04 h supera 0.02 kW/m², con al menos tres lecturas. Se invalida el viento horario si supera en más de 30 km/h la mediana de la red, con al menos cinco estaciones; tres o más horas marcadas invalidan todo el día. Estas horas no se imputan. El diagnóstico identifica 1 071 registros excluidos por D15 (Anexo A6); el viento diario máximo de la muestra queda en 7.3 m/s. El horario local se mantiene como supuesto pendiente de confirmación con SIMA.

Sensibilidad a la imputación. Al exigir al menos 18 horas observadas de PM2.5, sin imputación, 429 registros (2.8 %) dejan de ser evaluables. Entre los 14 961 comparables, 101 (0.7 %) cambian de clase. La clasificación cambia poco en ese subconjunto, aunque no puede evaluarse de la misma manera en los días que pierden cobertura.

4. Exploración descriptiva

4.1 Distribución de las superaciones

El 26.3 % de los estación-días supera 25 µg/m³. La mediana del PM2.5 diario es 18.2 µg/m³, con asimetría positiva (2.0) y episodios de hasta 166 µg/m³ (Anexo A2). La superación es más frecuente en seca-fría (37.2 %) y seca-cálida (35.5 %) que en cálida-húmeda (12.4 %). Como antecedente local, Martínez-Cinco et al. (2016), en campañas de otoño de 2007 y verano de 2008, relacionan la acumulación otoñal de partículas con viento débil y menor altura de mezcla. Nuestro análisis no mide esta última. La proporción anual oscila entre 24.0 % y 29.7 %, sin un patrón monotónico en los cinco años (Anexo A3). La Figura 1 muestra un gradiente espacial amplio: SE2 y SO superan en casi la mitad de sus días y SUR en menos del 10 %. El patrón estacional, además, cambia según la estación: SO pasa de 75 % en seca-fría a 42 % en seca-cálida, CE alcanza su máximo en seca-cálida (55 %) y NTE casi no varía (17–23 %).

Interpretación. Las diferencias entre estaciones y temporadas justifican incluir ambas en M0; su capacidad de clasificación aún debe evaluarse. Como el patrón estacional varía entre sitios, el protocolo incorpora una comparación adicional con interacción estación × temporada.

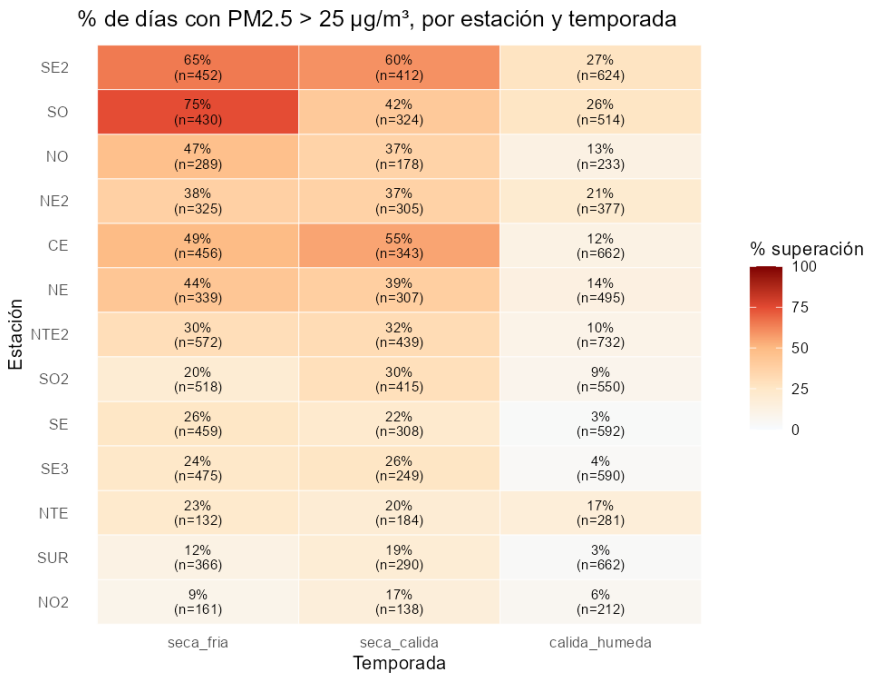


Figura 1: Porcentaje de estación-días con PM2.5 > 25 µg/m³ por estación y temporada, 2021–2025 (n por celda entre paréntesis). Elaboración propia con datos de SIMA.

4.2 Meteorología de los días con superación

La Figura 2 compara las clases mediante la diferencia de medias estandarizada (SMD): global, por temporada y en anomalías (valor menos la media de su estación y temporada). El centrado reduce las diferencias de nivel entre estación y temporada, pero sigue siendo una comparación descriptiva: no estima por sí solo la mejora de M1 frente a M0.

- **Temperatura.** La diferencia global es casi nula (SMD −0.04), mientras que en cada temporada es positiva (0.23 a 0.84); en las anomalías alcanza 0.50. Este cambio de signo al agrupar es compatible con un patrón de Simpson y muestra por qué conviene comparar por temporada. Las correlaciones globales con PM2.5 son débiles ($|\rho| \leq 0.27$; Anexo A4).
- **Viento.** Los días con superación presentan menor rapidez (SMD −0.55 global; −0.35 en anomalías; −0.75 en seca-fría). El resultado es compatible con menor ventilación, aunque no permite atribuirle por sí solo los episodios de PM2.5.
- **Presión.** Presenta el mayor contraste en anomalías (SMD −0.59): los días con superación tienen presión inferior al promedio de su estación y temporada. Su combinación con temperaturas más altas plantea una posible relación con situaciones previas a frentes, pendiente de contrastar con información sinóptica.
- **Lluvia.** Se registran menos horas con lluvia en los días con superación (SMD −0.26 global; −0.16 en anomalías). Humedad, radiación y viento meridional presentan diferencias de medias pequeñas en anomalías ($|\text{SMD}| \leq 0.14$); esto no descarta otras asociaciones.

Interpretación. Las diferencias en anomalías ($|\text{SMD}| \leq 0.6$) justifican evaluar la meteorología en M1. Su aporte al desempeño fuera de muestra sigue pendiente: estos descriptivos no permiten asegurar una mejora ni anticipar su magnitud.

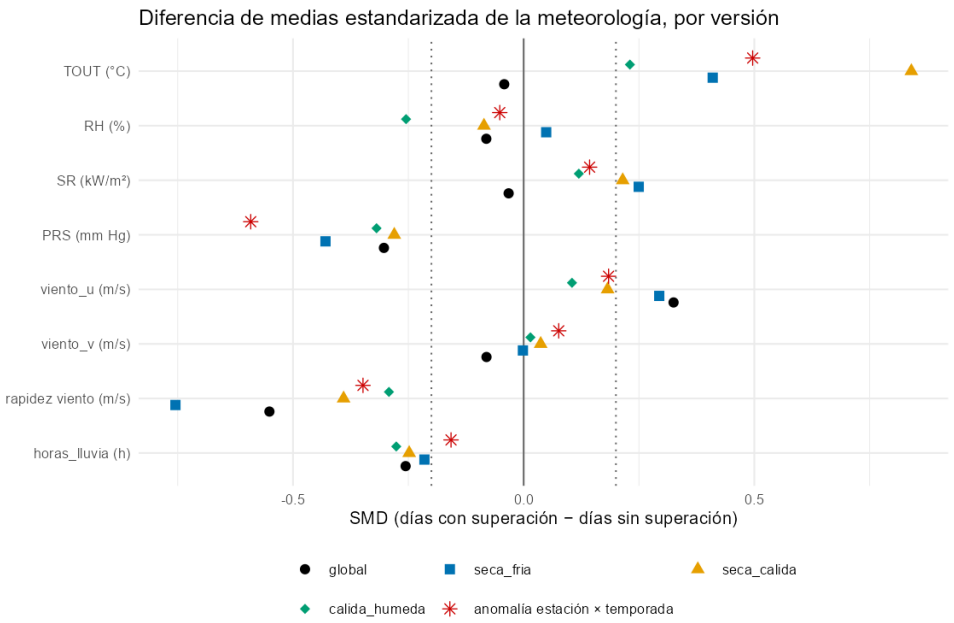


Figura 2: Diferencia de medias estandarizada (días con superación menos días sin superación) por variable: global, por temporada y como anomalía respecto de su estación y temporada. Líneas punteadas en ±0.2. Elaboración propia con datos de SIMA.

4.3 Implicaciones para el modelado

Hay correlaciones entre predictores (*u* y rapidez, ρ = −0.61; TOUT y SR, ρ = 0.53), por lo que los coeficientes del LDA se interpretarán en conjunto. El PCA explorará esa estructura. El 92.2 % de los registros tiene cero horas con lluvia y tienen asimetría de 7.37; la rapidez presenta una asimetría menor, de 0.49 (Anexo A5). La revisión de distribuciones y covarianzas se hará por clase; las transformaciones se decidirán con validación progresiva en 2021–2023.

5. Síntesis

Qué se descubrió. El 26.3 % de la muestra supera la referencia de PM2.5, con diferencias por estación y temporada. En la comparación de anomalías, los días con superación presentan mayor temperatura, menor presión, menor rapidez del viento y menos horas con lluvia. Las inconsistencias detectadas motivaron la regla D15.

Relación con el objetivo. Los contrastes observados respaldan incluir estación y temporada en M0. Las diferencias meteorológicas (Figura 2) motivan comparar M1 con M0, sin dar por demostrada una mejora.

Limitaciones. Los resultados describen la muestra seleccionada, cuya retención es desigual y modifica la proporción de superaciones en algunas estaciones. El umbral es una referencia fija; el análisis es retrospectivo. Hay dependencia entre fechas y estaciones, y los años de prueba ya participaron en un ensayo preliminar. Faltan datos de altura de mezcla y confirmación de la unidad de lluvia y del horario.

Análisis pendientes. PCA exploratorio; M0 y M1 con LDA y validación progresiva; ΔAUC con bootstrap por bloques (sensibilidad con 7 y 28 días); logística como robustez; revisión de supuestos; y sensibilidades con 15 µg/m³, PM2.5 solo con horas observadas, componentes principales como predictores, interacción estación × temporada y M0 en la muestra con solo PM2.5 válido.

Camino a seguir. Modelos y validación en la etapa 3 (15 de octubre) y una aplicación sencilla para explorar los resultados por estación y temporada en la exposición (22 de octubre).

Nuevas preguntas. ¿Las diferencias meteorológicas se traducirán en mejor clasificación fuera de muestra? ¿Cuánto cambiará la comparación al incluir la interacción estación × temporada o ampliar la muestra de M0? La relación con frentes y el uso de meteorología pronosticada quedan para trabajos posteriores.

Repositorio. https://github.com/Leo-issacs/reto-sima-multivariados (README, sección «Cómo reproducir»).

Uso de IA. Usamos Claude y Codex para revisar código, proponer pruebas de calidad y editar la redacción; las decisiones, la verificación de cifras y la interpretación son del equipo (Anexo B).

Referencias

Austin, P. C. (2009). Balance diagnostics for comparing the distribution of baseline covariates between treatment groups in propensity-score matched samples. *Statistics in Medicine, 28*(25), 3083–3107. https://doi.org/10.1002/sim.3697

Estévez, J., Gavilán, P., & Giráldez, J. V. (2011). Guidelines on validation procedures for meteorological data from automatic weather stations. *Journal of Hydrology, 402*(1–2), 144–154. https://www.sciencedirect.com/science/article/pii/S0022169411001594

Fiebrich, C. A., Morgan, C. R., McCombs, A. G., Hall, P. K., & McPherson, R. A. (2010). Quality assurance procedures for mesoscale meteorological data. *Journal of Atmospheric and Oceanic Technology, 27*(10), 1565–1582. https://doi.org/10.1175/2010JTECHA1433.1

Hernández-Romero, K., Hernández-Romero, I. M., Mendoza, A., Pérez-Rodríguez, M., Barajas-Villarruel, L. R., Medellín-Carrillo, S., & González, L. T. (2026). Persistent air pollution regimes and regulatory exceedances of PM10, PM2.5, and O3 in the Monterrey Metropolitan Area, Mexico. *City and Environment Interactions, 31*, 100410. https://doi.org/10.1016/j.cacint.2026.100410

Johnson, R. A., & Wichern, D. W. (2007). *Applied multivariate statistical analysis* (6th ed.). Pearson.

Martínez-Cinco, M. A., Santos-Guzmán, J., & Mejía-Velázquez, G. M. (2016). Source apportionment of PM2.5 for supporting control strategies in the Monterrey Metropolitan Area, Mexico. *Journal of the Air & Waste Management Association, 66*(6), 631–642. https://doi.org/10.1080/10962247.2016.1159259

Mohd Shafi'i, M. S., & Juahir, H. (2024). Assessment of spatial air quality on the East Coast of Peninsular Malaysia utilizing environmetric techniques. *Environmental Monitoring and Assessment, 196*(7), 640. https://doi.org/10.1007/s10661-024-12787-9

Orellano, P., Reynoso, J., Quaranta, N., Bardach, A., & Ciapponi, A. (2020). Short-term exposure to particulate matter (PM10 and PM2.5), nitrogen dioxide (NO2), and ozone (O3) and all-cause and cause-specific mortality: Systematic review and meta-analysis. *Environment International, 142*, 105876. https://doi.org/10.1016/j.envint.2020.105876

Secretaría de Salud. (2021, 27 de octubre). NOM-025-SSA1-2021, Salud ambiental. Criterio para evaluar la calidad del aire ambiente, con respecto a las partículas suspendidas PM10 y PM2.5. *Diario Oficial de la Federación*.

World Health Organization. (2021). *WHO global air quality guidelines: Particulate matter (PM2.5 and PM10), ozone, nitrogen dioxide, sulfur dioxide and carbon monoxide*. https://www.who.int/publications/i/item/9789240034228

Anexo A. Tablas y figuras complementarias

A1. Pérdidas de la muestra por requisito y retención por estación

Tabla 2: Pérdidas de la muestra por requisito, sobre los 23 738 estación-días posibles (13 estaciones × 2021–2025). Un día puede fallar más de un requisito.

Requisito	Estación-días	% del universo
Universo (13 estaciones x 2021-2025)	23 738	100.0
Pierde por PM2.5 (< 18 h válidas)	3 820	16.1
Pierde por meteorología incompleta (algún predictor de M1 < 18 h)	5 763	24.3
de ellos: solo falta PM2.5	2 585	10.9
de ellos: solo falta meteorología	4 528	19.1
de ellos: faltan ambos	1 235	5.2
de la meteorología: días retirados por la regla D15 (SR nocturna o viento contra la red)	1 071	4.5
por SR nocturna	931	3.9
por viento contra la red	141	0.6
Muestra final (PM2.5 y meteorología completas)	15 390	64.8

Tabla 3: Retención por estación: estación-días en la muestra sobre los 1 826 días de 2021–2025.

Estación	Días posibles	Días en la muestra	% retenido
NTE2	1 826	1 743	95.5
SE2	1 826	1 488	81.5
SO2	1 826	1 483	81.2
CE	1 826	1 461	80.0
SE	1 826	1 359	74.4
SUR	1 826	1 318	72.2
SE3	1 826	1 314	72.0
SO	1 826	1 268	69.4
NE	1 826	1 141	62.5
NE2	1 826	1 007	55.1
NO	1 826	700	38.3
NTE	1 826	597	32.7
NO2	1 826	511	28.0

A2. PM2.5 diario por estación

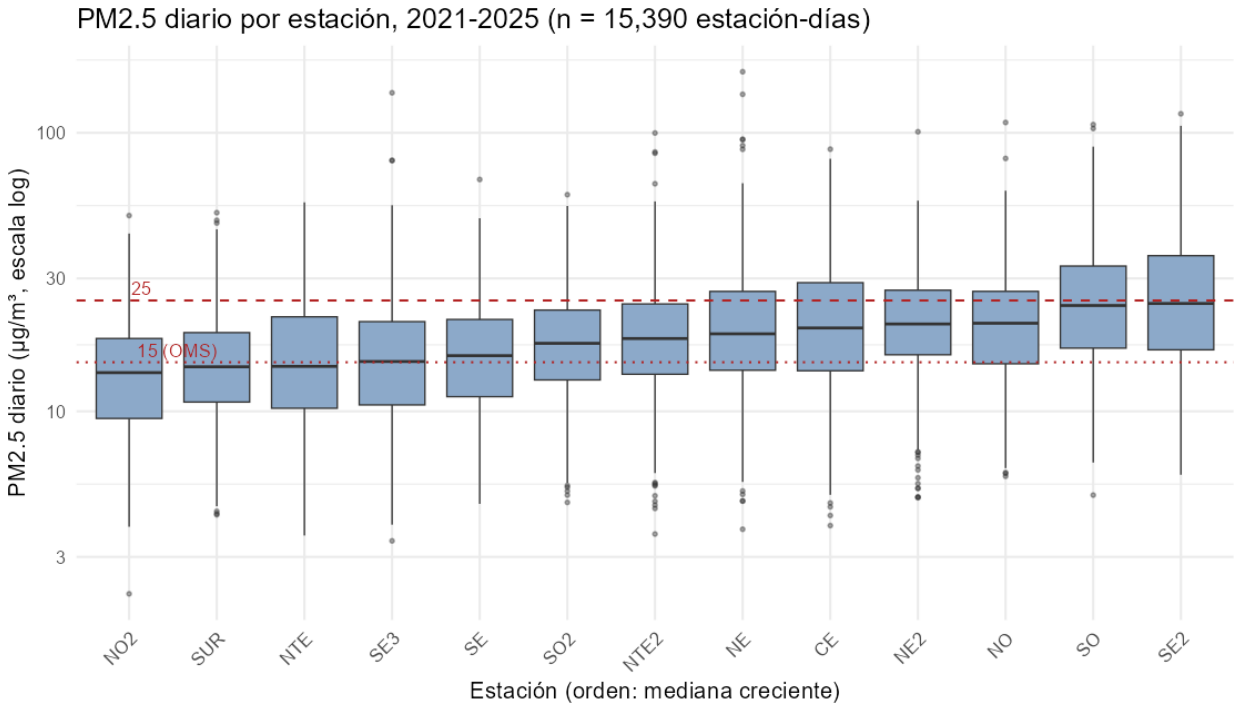


Figura 3: PM2.5 diario por estación, 2021–2025 (diagrama de caja, escala logarítmica). Las líneas marcan 15 µg/m³ (guía de 24 h de la OMS) y 25 µg/m³. Elaboración propia con datos de SIMA.

A3. Porcentaje mensual de superación por año

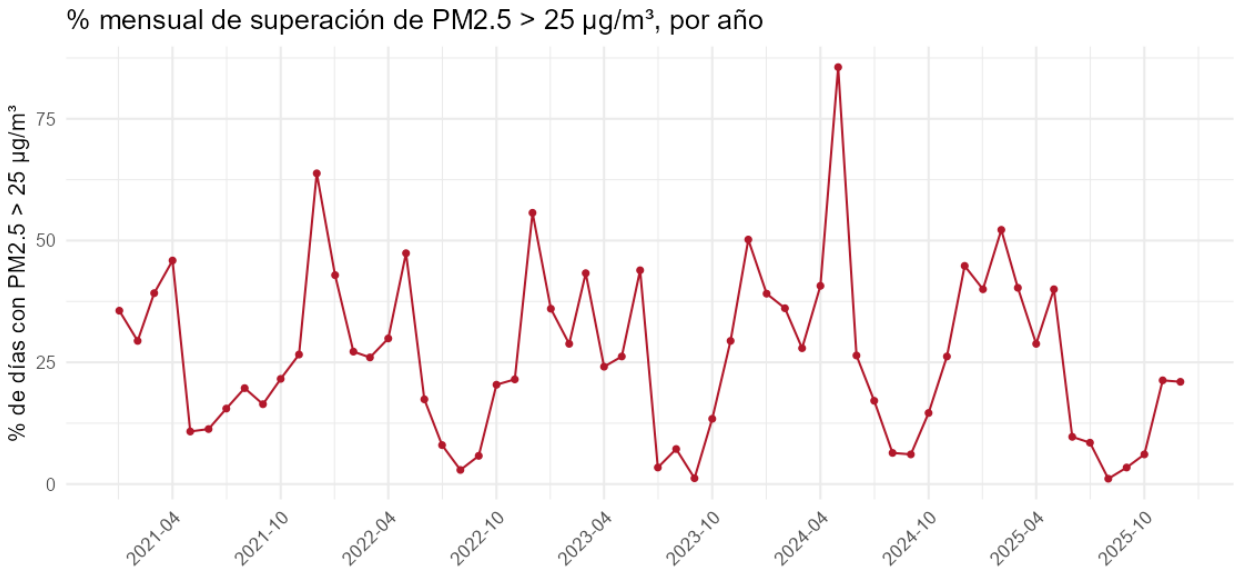


Figura 4: Porcentaje mensual de estación-días con PM2.5 > 25 µg/m³, 2021–2025. Elaboración propia con datos de SIMA.

A4. Matriz de correlación de Spearman

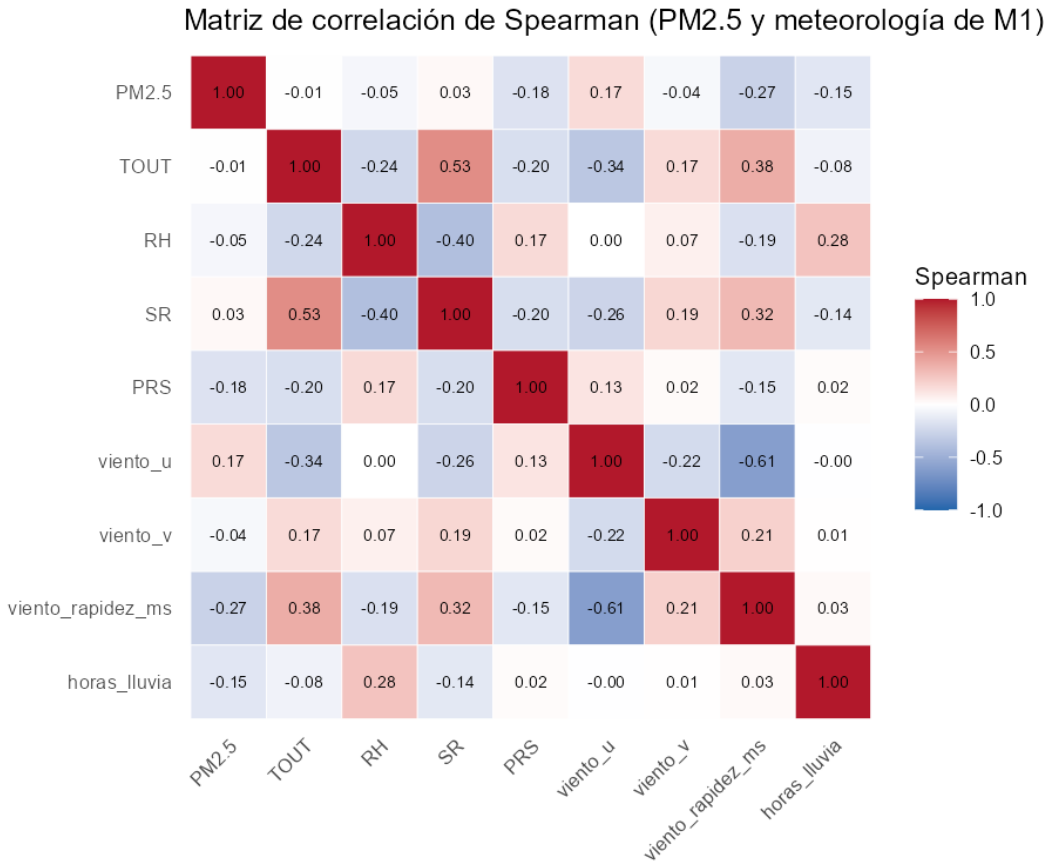


Figura 5: Correlación de Spearman entre el PM2.5 diario y los ocho predictores meteorológicos de M1. Elaboración propia con datos de SIMA.

A5. Descriptivos de PM2.5 y de los ocho predictores

Tabla 4: Descriptivos de la muestra: n, media, desviación estándar (DE), cuartiles y asimetría. Extremos = valores mayores que Q3 + 3·IQR.

Variable	n	Media	DE	Q1	Mediana	Q3	Asimetría	Extremos
PM2.5	15 390	20.58	11.00	12.96	18.18	25.54	1.97	98
TOUT	15 390	23.59	6.01	19.89	24.84	28.30	-0.82	0
RH	15 390	56.76	14.96	47.58	57.62	66.92	-0.32	0
SR	15 390	0.14	0.07	0.09	0.14	0.19	-0.22	0
PRS	15 390	715.28	8.45	710.73	714.37	721.11	0.10	0
viento_u	15 390	-1.16	1.21	-1.95	-1.15	-0.43	0.19	2
viento_v	15 390	0.18	1.09	-0.44	0.22	0.80	-0.28	0
viento_rapidez_ms	15 390	2.33	0.80	1.76	2.26	2.82	0.49	4
horas_lluvia	15 390	0.30	1.49	0.00	0.00	0.00	7.37	1196

A6. Días retirados por la regla D15 (Sección 3), por estación

Tabla 5: Estación-días de la muestra retirados por la regla D15 (2021–2025, 13 estaciones). Un día puede caer en ambas pruebas. Las dos últimas columnas cuentan los días con al menos una hora invalidada por cada prueba.

Estación	Días retirados	Por SR nocturna	Por viento	Días con SR nocturna (M)	Días con viento invalidado (E)
NO2	456	455	1	541	1
SE3	313	313	0	352	0
SO2	103	1	102	1	116

CE	92	92	0	95	1
NE2	46	9	37	103	55
NO	35	35	1	63	3
SO	25	25	0	34	1
SE2	1	1	0	1	0
NE	0	0	0	2	0
NTE	0	0	0	8	0
NTE2	0	0	0	0	0
SE	0	0	0	0	0
SUR	0	0	0	12	1
TOTAL	1071	931	141	1212	178

Anexo B. Declaratoria de uso de IA (Opción B)

- **Herramientas:** Claude (Anthropic): Claude Opus y Claude Code; Codex (OpenAI).
- **Uso realizado:**
  - Claude Opus: reformulación de la pregunta tras la retroalimentación, protocolo de análisis, búsqueda de literatura, detección de las fallas de viento y radiación al revisar los descriptivos, y redacción y edición del texto.
  - Claude Code: scripts de R de limpieza (regla D15), validación, pruebas sintéticas, construcción de la muestra, descriptivos y figuras (`scripts/03` a `06`), y armado del documento en Quarto.
  - Codex: revisión del protocolo, comprobación independiente de cifras y edición de la redacción del informe.
- **Secciones:** todo el informe, `docs/etapa2/protocolo.md` y los scripts mencionados.
- **Validación realizada por los estudiantes:** Leonardo Orozco revisó el protocolo y la redacción final, ejecutó en RStudio el cuaderno de auditoría y comparó las cifras de las secciones 3 y 4 con los archivos de `output/etapa2/`. Ignacio Kume y Daniel Ayala leyeron los artículos de sus fichas e investigaron nuevas por el cambio de pregunta central; Pablo Alonso Robles Nava revisó la redacción.
- Confirmamos que revisamos y verificamos el contenido final y asumimos la responsabilidad sobre él.

Anexo C. Diccionario de datos

Una fila por columna de cada base publicada en `data/clean/`: horaria (`sima_horario_limpio_AAAA.csv`, 39 columnas), diaria (`sima_diario_2020_2025.csv`, 40) y muestra de la etapa 2 (`muestra_pm25_2021_2025.csv`, 24). Lo genera `scripts/06b_anexo_c_diccionario.R`, que también agrega el dominio y los porcentajes de nulos a `data/clean/DICCIONARIO.csv`.

% nulos antes: porcentaje de horas faltantes de la variable en el Excel original, sobre las 762 792 horas de la malla de todas las hojas-año 2020–2025, incluidas las 8 189 horas sin fila; en las bases diaria y muestra se repite el de la variable horaria de origen. Las columnas construidas en la limpieza (banderas, conteos de horas, componentes del viento, temporada, núcleos, indicadores) dicen “no aplica (derivada)”. **% nulos después:** porcentaje de celdas vacías en la base publicada. **Dominio:** para una medición, el rango de validez aplicado por hora y el rango observado después de la limpieza; para una bandera, los códigos presentes; para una categórica, sus valores.

Base	Columna	Descripción	Tipo	Unidad	Dominio o valores permitidos	% nulos antes	% nulos después
Horaria	estacion	Código de estación SIMA (hoja del Excel)	categórico		CE, NE, NE2, NE3, NO, NO2, NO3, NTE, NTE2, SE, SE2, SE3, SO, SO2, SUR	no aplica (clave)	0
Horaria	fecha_hora	Hora local de la medición (00:00 a 23:00), sin zona horaria	fecha-hora		2020-01-01 00:00:00 a 2025-12-31 23:00:00	no aplica (clave)	0
Horaria	confinamiento_2020	1 entre 2020-04-01 y 2020-05-31; 0 en el resto	binario		0, 1	no aplica (derivada)	0
Horaria	CO	Valor horario de monóxido de carbono, ya limpio (incluye imputadas)	numérico	ppm	Validez: operación del año, 0 a 8–20 (máx. según año); observado: 0 a 17.71	14.2	13.7
Horaria	NO	Valor horario de monóxido de nitrógeno, ya limpio (incluye imputadas)	numérico	ppb	Validez: operación del año, 0 a 350–500 (máx. según año); observado: 0.3 a 500	17.6	16.7
Horaria	NO2	Valor horario de dióxido de nitrógeno, ya limpio (incluye imputadas)	numérico	ppb	Validez: operación del año, 0 a 100–200 (máx. según año); observado: 0 a 188.6	18.3	17.7
Horaria	NOX	Valor horario de óxidos de nitrógeno, ya limpio (incluye imputadas)	numérico	ppb	Validez: operación del año, 0 a 400–500 (máx. según año); observado: 0.5 a 500	17.7	16.7
Horaria	O3	Valor horario de ozono, ya limpio (incluye imputadas)	numérico	ppb	Validez: operación del año, 0 a 153–185 (máx. según año); observado: 0.5 a 184	15.6	14.4
Horaria	PM10	Valor horario de PM10, ya limpio (incluye imputadas)	numérico	µg/m³	Validez: operación del año, 0 a 800–999 (máx. según año); observado: 1 a 999	5.7	4.7
Horaria	PM2.5	Valor horario de PM2.5, ya limpio (incluye imputadas)	numérico	µg/m³	Validez: operación del año, 0 a 205.9–999 (máx. según año); observado: 0 a 763	26.0	23.2
Horaria	PRS	Valor horario de presión atmosférica, ya limpio (incluye imputadas)	numérico	mm Hg	Validez: fabricante, 449.9 a 824.9; S si salto > 10 mm Hg; observado: 680 a 750	6.1	5.7
Horaria	RAINF	Precipitación horaria tal como viene en el Excel; solo se usa en horas_lluvia	numérico	mm/h (no confirmada)	Validez: 0 a máx. de operación del año (25–80); observado: 0 a 74	5.8	5.8
Horaria	RH	Valor horario de humedad relativa, ya limpio (incluye imputadas)	numérico	%	Validez: fabricante, 0 a 100; E contra la red; observado: 0 a 100	12.3	12.3
Horaria	SO2	Valor horario de dióxido de azufre, ya	numérico	ppb	Validez: operación del año, 0 a 150–405 (máx. según año); observado: 0	15.9	13.7

Base	Columna	Descripción	Tipo	Unidad	Dominio o valores permitidos	% nulos antes	% nulos después
		limpio (incluye imputadas)			a 404.7		
Horaria	SR	Valor horario de radiación solar, ya limpio (incluye imputadas)	numérico	kW/m²	Validez: fabricante, 0 a 1.4; M si SR nocturna (D15); observado: 0 a 1.4	4.7	11.0
Horaria	TOUT	Valor horario de temperatura del aire, ya limpio (incluye imputadas)	numérico	°C	Validez: fabricante, -50 a 50; L si |TOUT| ≥ 49.9; E contra la red; observado: -8.75 a 45.1	7.9	7.5
Horaria	WSR	Velocidad horaria del viento, validada y sin imputar	numérico	km/h	Validez: fabricante, 0 a 180; E contra la red (D15); observado: 0.1 a 44.5	7.9	8.5
Horaria	WDR	Dirección de donde sopla el viento, validada y sin imputar	numérico	grados	Validez: fabricante, 0 a 360; E con WSR (D15); observado: 1 a 360	9.3	9.9
Horaria	viento_u	Componente este-oeste del viento, derivada de WSR y WDR	numérico	m/s	Derivada de WSR y WDR válidos; observado: -10.39 a 10.12	no aplica (derivada)	12.0
Horaria	viento_v	Componente norte-sur del viento, derivada de WSR y WDR	numérico	m/s	Derivada de WSR y WDR válidos; observado: -11.46 a 9.464	no aplica (derivada)	12.0
Horaria	f_CO	Bandera de calidad de la hora para CO	categórico (1 letra)		V válida original; N falta original; F fuera de rango; K racha ≥ 24 h idéntica; C racha ≥ 6 h conservada; I imputada	no aplica (derivada)	0
Horaria	f_NO	Bandera de calidad de la hora para NO	categórico (1 letra)		V válida original; N falta original; F fuera de rango; K racha ≥ 24 h idéntica; C racha ≥ 6 h conservada; I imputada	no aplica (derivada)	0
Horaria	f_NO2	Bandera de calidad de la hora para NO2	categórico (1 letra)		V válida original; N falta original; K racha ≥ 24 h idéntica; C racha ≥ 6 h conservada; I imputada	no aplica (derivada)	0
Horaria	f_NOX	Bandera de calidad de la hora para NOX	categórico (1 letra)		V válida original; N falta original; F fuera de rango; K racha ≥ 24 h idéntica; C racha ≥ 6 h conservada; I imputada	no aplica (derivada)	0
Horaria	f_O3	Bandera de calidad de la hora para O3	categórico (1 letra)		V válida original; N falta original; F fuera de rango; C racha ≥ 6 h conservada; I imputada	no aplica (derivada)	0
Horaria	f_PM10	Bandera de calidad de la hora para PM10	categórico (1 letra)		V válida original; N falta original; F fuera de rango; R PM2.5 > PM10; K racha ≥ 24 h idéntica; C racha ≥ 6 h conservada; I imputada; X imputación revertida	no aplica (derivada)	0
Horaria	f_PM2.5	Bandera de calidad de la hora para PM2.5	categórico (1 letra)		V válida original; N falta original; R PM2.5 > PM10; K racha ≥ 24 h idéntica; C racha ≥ 6 h conservada; I imputada; X imputación revertida	no aplica (derivada)	0
Horaria	f_PRS	Bandera de calidad de la hora para PRS	categórico (1 letra)		V válida original; N falta original; P regla de notas del PDF; S salto horario; K racha ≥ 24 h idéntica; C racha ≥ 6 h conservada; I imputada; X imputación revertida	no aplica (derivada)	0
Horaria	f_RAINF	Bandera de calidad de la hora para RAINF	categórico (1 letra)		V válida original; N falta original; F fuera de rango; C racha ≥ 6 h conservada	no aplica (derivada)	0
Horaria	f_RH	Bandera de calidad de la hora para RH	categórico (1 letra)		V válida original; N falta original; F fuera de rango; E consistencia espacial; C racha ≥ 6 h conservada; I imputada; X imputación revertida	no aplica (derivada)	0
Horaria	f_SO2	Bandera de calidad de la hora para SO2	categórico (1 letra)		V válida original; N falta original; C racha ≥ 6 h conservada; I imputada	no aplica (derivada)	0
Horaria	f_SR	Bandera de calidad de la hora para SR	categórico (1 letra)		V válida original; N falta original; F fuera de rango; P regla de notas del PDF; M SR nocturna (D15); C racha ≥ 6 h conservada; I imputada; X imputación revertida	no aplica (derivada)	0
Horaria	f_TOUT	Bandera de calidad de la hora para TOUT	categórico (1 letra)		V válida original; N falta original; F fuera de rango; S salto horario; L TOUT saturada; E consistencia espacial; I imputada	no aplica (derivada)	0
Horaria	f_WSR	Bandera de calidad de la hora para WSR	categórico (1 letra)		V válida original; N falta original; F fuera de rango; P regla de notas del PDF; E consistencia espacial; C racha ≥ 6 h conservada	no aplica (derivada)	0

Base	Columna	Descripción	Tipo	Unidad	Dominio o valores permitidos	% nulos antes	% nulos después
Horaria	f_WDR	Bandera de calidad de la hora para WDR	categórico (1 letra)		V válida original; N falta original; F fuera de rango; E consistencia espacial	no aplica (derivada)	0
Horaria	f_uv	Bandera de calidad de las componentes u y v del viento	categórico (1 letra)		V válida original; N falta original; F fuera de rango; P regla de notas del PDF; E consistencia espacial; I imputada	no aplica (derivada)	0
Horaria	nox_inconsistente	1 si |NOX − (NO+NO2)| > máx(1 ppb, 10 % de NOX); solo bandera	binario		0, 1; vacío si falta NO, NO2 o NOX	no aplica (derivada)	18.2
Horaria	f_obs_TOUT	Bandera de TOUT antes de imputar; conserva la causa de invalidez	categórico (1 letra)		V válida original; N falta original; F fuera de rango; S salto horario; L TOUT saturada; E consistencia espacial	no aplica (derivada)	0
Horaria	f_obs_RH	Bandera de RH antes de imputar; conserva la causa de invalidez	categórico (1 letra)		V válida original; N falta original; F fuera de rango; E consistencia espacial; C racha ≥ 6 h conservada	no aplica (derivada)	0
Diaria	estacion	Código de estación SIMA (hoja del Excel)	categórico		CE, NE, NE2, NE3, NO, NO2, NO3, NTE, NTE2, SE, SE2, SE3, SO, SO2, SUR	no aplica (clave)	0
Diaria	fecha	Día calendario local	fecha		2020-01-01 a 2025-12-31	no aplica (clave)	0
Diaria	anio	Año calendario	entero		2020 a 2025	no aplica (derivada)	0
Diaria	temporada	Temporada regional: seca fría (nov–feb), seca cálida (mar–may), cálida húmeda (jun–oct)	categórico		calida_humeda, seca_calida, seca_fria	no aplica (derivada)	0
Diaria	confinamiento_2020	1 entre 2020-04-01 y 2020-05-31; 0 en el resto	binario		0, 1	no aplica (derivada)	0
Diaria	CO	Media diaria de monóxido de carbono (≥ 18 h válidas, incluye imputadas)	numérico	ppm	Validez por hora: operación del año, 0 a 8–20 (máx. según año); observado (media diaria): 0.05 a 9.2	14.2	14.7
Diaria	NO	Media diaria de monóxido de nitrógeno (≥ 18 h válidas, incluye imputadas)	numérico	ppb	Validez por hora: operación del año, 0 a 350–500 (máx. según año); observado (media diaria): 0.5 a 327.4	17.6	18.1
Diaria	NO2	Media diaria de dióxido de nitrógeno (≥ 18 h válidas, incluye imputadas)	numérico	ppb	Validez por hora: operación del año, 0 a 100–200 (máx. según año); observado (media diaria): 0.05 a 95.18	18.3	18.9
Diaria	NOX	Media diaria de óxidos de nitrógeno (≥ 18 h válidas, incluye imputadas)	numérico	ppb	Validez por hora: operación del año, 0 a 400–500 (máx. según año); observado (media diaria): 0.5 a 381.8	17.7	18.0
Diaria	O3_max8h	Máximo diario del promedio móvil de 8 h de ozono	numérico	ppb	Derivada de O3 válido (≥ 6 de 8 h); observado: 1.75 a 138.3	no aplica (derivada)	15.4
Diaria	PM10	Media diaria de PM10 (≥ 18 h válidas, incluye imputadas)	numérico	µg/m³	Validez por hora: operación del año, 0 a 800–999 (máx. según año); observado (media diaria): 4 a 333.7	5.7	5.8
Diaria	PM2.5	Media diaria de PM2.5 (≥ 18 h válidas, incluye imputadas)	numérico	µg/m³	Validez por hora: operación del año, 0 a 205.9–999 (máx. según año); observado (media diaria): 2.211 a 165.7	26.0	25.2
Diaria	SO2	Media diaria de dióxido de azufre (≥ 18 h válidas, incluye imputadas)	numérico	ppb	Validez por hora: operación del año, 0 a 150–405 (máx. según año); observado (media diaria): 0.575 a 61.78	15.9	15.0
Diaria	TOUT	Media diaria de temperatura del aire (≥ 18 h válidas, incluye imputadas)	numérico	°C	Validez por hora: fabricante, -50 a 50; L si |TOUT| ≥ 49.9; E contra la red; observado (media diaria): -3.749 a 36.78	7.9	8.3
Diaria	RH	Media diaria de humedad relativa (≥ 18 h válidas, incluye imputadas)	numérico	%	Validez por hora: fabricante, 0 a 100; E contra la red; observado (media diaria): 5.583 a 98.28	12.3	13.3
Diaria	SR	Media diaria de radiación solar (≥ 18 h válidas, incluye imputadas)	numérico	kW/m²	Validez por hora: fabricante, 0 a 1.4; M si SR nocturna (D15); observado (media diaria): 0 a 0.539	4.7	12.0

Base	Columna	Descripción	Tipo	Unidad	Dominio o valores permitidos	% nulos antes	% nulos después
Diaria	PRS	Media diaria de presión atmosférica (≥ 18 h válidas, incluye imputadas)	numérico	mm Hg	Validez por hora: fabricante, 449.9 a 824.9; S si salto > 10 mm Hg; observado (media diaria): 681.8 a 747.7	6.1	6.5
Diaria	horas_lluvia	Horas del día con 0 < RAINF ≤ máximo de operación	entero	horas	0 a 24; observado: 0 a 24	no aplica (derivada)	5.8
Diaria	llovio	1 si hubo al menos una hora con lluvia	binario		0, 1	no aplica (derivada)	5.8
Diaria	viento_u	Media diaria de la componente este-oeste del viento	numérico	m/s	Derivada de WSR y WDR válidos; observado: -6.003 a 5.28	no aplica (derivada)	13.6
Diaria	viento_v	Media diaria de la componente norte-sur del viento	numérico	m/s	Derivada de WSR y WDR válidos; observado: -6.619 a 5.544	no aplica (derivada)	13.6
Diaria	viento_rapidez_ms	Media diaria de la rapidez horaria del viento, raíz de $u^2 + v^2$	numérico	m/s	≥ 0; observado: 0.179 a 7.527	no aplica (derivada)	13.6
Diaria	n_horas_CO	Horas válidas de CO en el día (incluye imputadas)	entero		0 a 24; observado: 0 a 24	no aplica (derivada)	0
Diaria	n_horas_NO	Horas válidas de NO en el día (incluye imputadas)	entero		0 a 24; observado: 0 a 24	no aplica (derivada)	0
Diaria	n_horas_NO2	Horas válidas de NO2 en el día (incluye imputadas)	entero		0 a 24; observado: 0 a 24	no aplica (derivada)	0
Diaria	n_horas_NOX	Horas válidas de NOX en el día (incluye imputadas)	entero		0 a 24; observado: 0 a 24	no aplica (derivada)	0
Diaria	n_horas_PM10	Horas válidas de PM10 en el día (incluye imputadas)	entero		0 a 24; observado: 0 a 24	no aplica (derivada)	0
Diaria	n_horas_PM2.5	Horas válidas de PM2.5 en el día (incluye imputadas)	entero		0 a 24; observado: 0 a 24	no aplica (derivada)	0
Diaria	n_horas_SO2	Horas válidas de SO2 en el día (incluye imputadas)	entero		0 a 24; observado: 0 a 24	no aplica (derivada)	0
Diaria	n_horas_TOUT	Horas válidas de TOUT en el día (incluye imputadas)	entero		0 a 24; observado: 0 a 24	no aplica (derivada)	0
Diaria	n_horas_RH	Horas válidas de RH en el día (incluye imputadas)	entero		0 a 24; observado: 0 a 24	no aplica (derivada)	0
Diaria	n_horas_SR	Horas válidas de SR en el día (incluye imputadas)	entero		0 a 24; observado: 0 a 24	no aplica (derivada)	0
Diaria	n_horas_PRS	Horas válidas de PRS en el día (incluye imputadas)	entero		0 a 24; observado: 0 a 24	no aplica (derivada)	0
Diaria	n_horas_viento	Horas válidas del día con componentes u y v	entero		0 a 24; observado: 0 a 24	no aplica (derivada)	0
Diaria	n_horas_O3_max8h	Horas válidas de O3 en el día	entero		0 a 24; observado: 0 a 24	no aplica (derivada)	0
Diaria	n_horas_RAINF	Horas válidas de RAINF en el día	entero		0 a 24; observado: 0 a 24	no aplica (derivada)	0
Diaria	n_horas_nox_inconsistente	Horas del día con nox_inconsistente = 1	entero		0 a 24; observado: 0 a 24	no aplica (derivada)	0
Diaria	en_nucleo_A	1 si el día completa el núcleo A (indicador de la etapa 1)	binario		0, 1	no aplica (derivada)	0

Base	Columna	Descripción	Tipo	Unidad	Dominio o valores permitidos	% nulos antes	% nulos después
Diaria	en_nucleo_B	1 si el día completa el núcleo B = A + PM2.5 (etapa 1)	binario		0, 1	no aplica (derivada)	0
Diaria	en_periodo_modelado	1 si el año está entre 2021 y 2025	binario		0, 1	no aplica (derivada)	0
Muestra	estacion	Código de estación SIMA (13; excluye NE3 y NO3)	categórico		CE, NE, NE2, NO, NO2, NTE, NTE2, SE, SE2, SE3, SO, SO2, SUR	no aplica (clave)	0
Muestra	fecha	Día calendario local	fecha		2021-01-01 a 2025-12-31	no aplica (clave)	0
Muestra	anio	Año calendario	entero		2021 a 2025	no aplica (derivada)	0
Muestra	temporada	Temporada regional: seca fría (nov–feb), seca cálida (mar–may), cálida húmeda (jun–oct)	categórico		calida_humeda, seca_calida, seca_fria	no aplica (derivada)	0
Muestra	confinamiento_2020	Siempre 0: la muestra excluye 2020	binario		0	no aplica (derivada)	0
Muestra	PM2.5	Media diaria de PM2.5 (≥ 18 h válidas, incluye imputadas)	numérico	µg/m³	Validez por hora: operación del año, 0 a 205.9–999 (máx. según año); observado (media diaria): 2.211 a 165.7	26.0	0
Muestra	supera_25	1 si la media diaria de PM2.5 supera 25 µg/m³	binario		0, 1	no aplica (derivada)	0
Muestra	supera_15	1 si supera 15 µg/m³ (sensibilidad, guía 24 h de la OMS)	binario		0, 1	no aplica (derivada)	0
Muestra	n_horas_PM2.5	Horas válidas de PM2.5 en el día (incluye imputadas)	entero		0 a 24; observado: 18 a 24	no aplica (derivada)	0
Muestra	TOUT	Media diaria de temperatura del aire (≥ 18 h válidas, incluye imputadas)	numérico	°C	Validez por hora: fabricante, -50 a 50; L si |TOUT| ≥ 49.9; E contra la red; observado (media diaria): -3.749 a 35.59	7.9	0
Muestra	RH	Media diaria de humedad relativa (≥ 18 h válidas, incluye imputadas)	numérico	%	Validez por hora: fabricante, 0 a 100; E contra la red; observado (media diaria): 5.667 a 97.08	12.3	0
Muestra	SR	Media diaria de radiación solar (≥ 18 h válidas, incluye imputadas)	numérico	kW/m²	Validez por hora: fabricante, 0 a 1.4; M si SR nocturna (D15); observado (media diaria): 0 a 0.432	4.7	0
Muestra	PRS	Media diaria de presión atmosférica (≥ 18 h válidas, incluye imputadas)	numérico	mm Hg	Validez por hora: fabricante, 449.9 a 824.9; S si salto > 10 mm Hg; observado (media diaria): 681.8 a 747.7	6.1	0
Muestra	viento_u	Media diaria de la componente este-oeste del viento	numérico	m/s	Derivada de WSR y WDR válidos; observado: -5.661 a 4.227	no aplica (derivada)	0
Muestra	viento_v	Media diaria de la componente norte-sur del viento	numérico	m/s	Derivada de WSR y WDR válidos; observado: -6.619 a 4.516	no aplica (derivada)	0
Muestra	viento_rapidez_ms	Media diaria de la rapidez horaria del viento, raíz de $u^2 + v^2$	numérico	m/s	≥ 0; observado: 0.307 a 7.251	no aplica (derivada)	0
Muestra	horas_lluvia	Horas del día con 0 < RAINF ≤ máximo de operación	entero	horas	0 a 24; observado: 0 a 24	no aplica (derivada)	0
Muestra	llovio	1 si hubo al menos una hora con lluvia	binario		0, 1	no aplica (derivada)	0
Muestra	n_horas_TOUT	Horas válidas de TOUT en el día (incluye imputadas)	entero		0 a 24; observado: 18 a 24	no aplica (derivada)	0
Muestra	n_horas_RH	Horas válidas de RH en el día (incluye	entero		0 a 24; observado: 18 a 24	no aplica	0

Base	Columna	Descripción	Tipo	Unidad	Dominio o valores permitidos	% nulos antes	% nulos después
		imputadas)				(derivada)	
Muestra	n_horas_SR	Horas válidas de SR en el día (incluye imputadas)	entero		0 a 24; observado: 18 a 24	no aplica (derivada)	0
Muestra	n_horas_PRS	Horas válidas de PRS en el día (incluye imputadas)	entero		0 a 24; observado: 18 a 24	no aplica (derivada)	0
Muestra	n_horas_viento	Horas válidas del día con componentes u y v	entero		0 a 24; observado: 18 a 24	no aplica (derivada)	0
Muestra	n_horas_RAINF	Horas válidas de RAINF en el día	entero		0 a 24; observado: 18 a 24	no aplica (derivada)	0